

ENHANCING SEA ICE SEGMENTATION MODEL

EXPLORING NEURAL NETWORK ENSEMBLES AND OPTIMIZATION
STRATEGIES FOR IMPROVED PERFORMANCE

PROFESSORES

GEORGE D. C. CAVALCANTI

TSANG ING REN

BRUNO HENRIQUE DOS SANTOS MARQUES

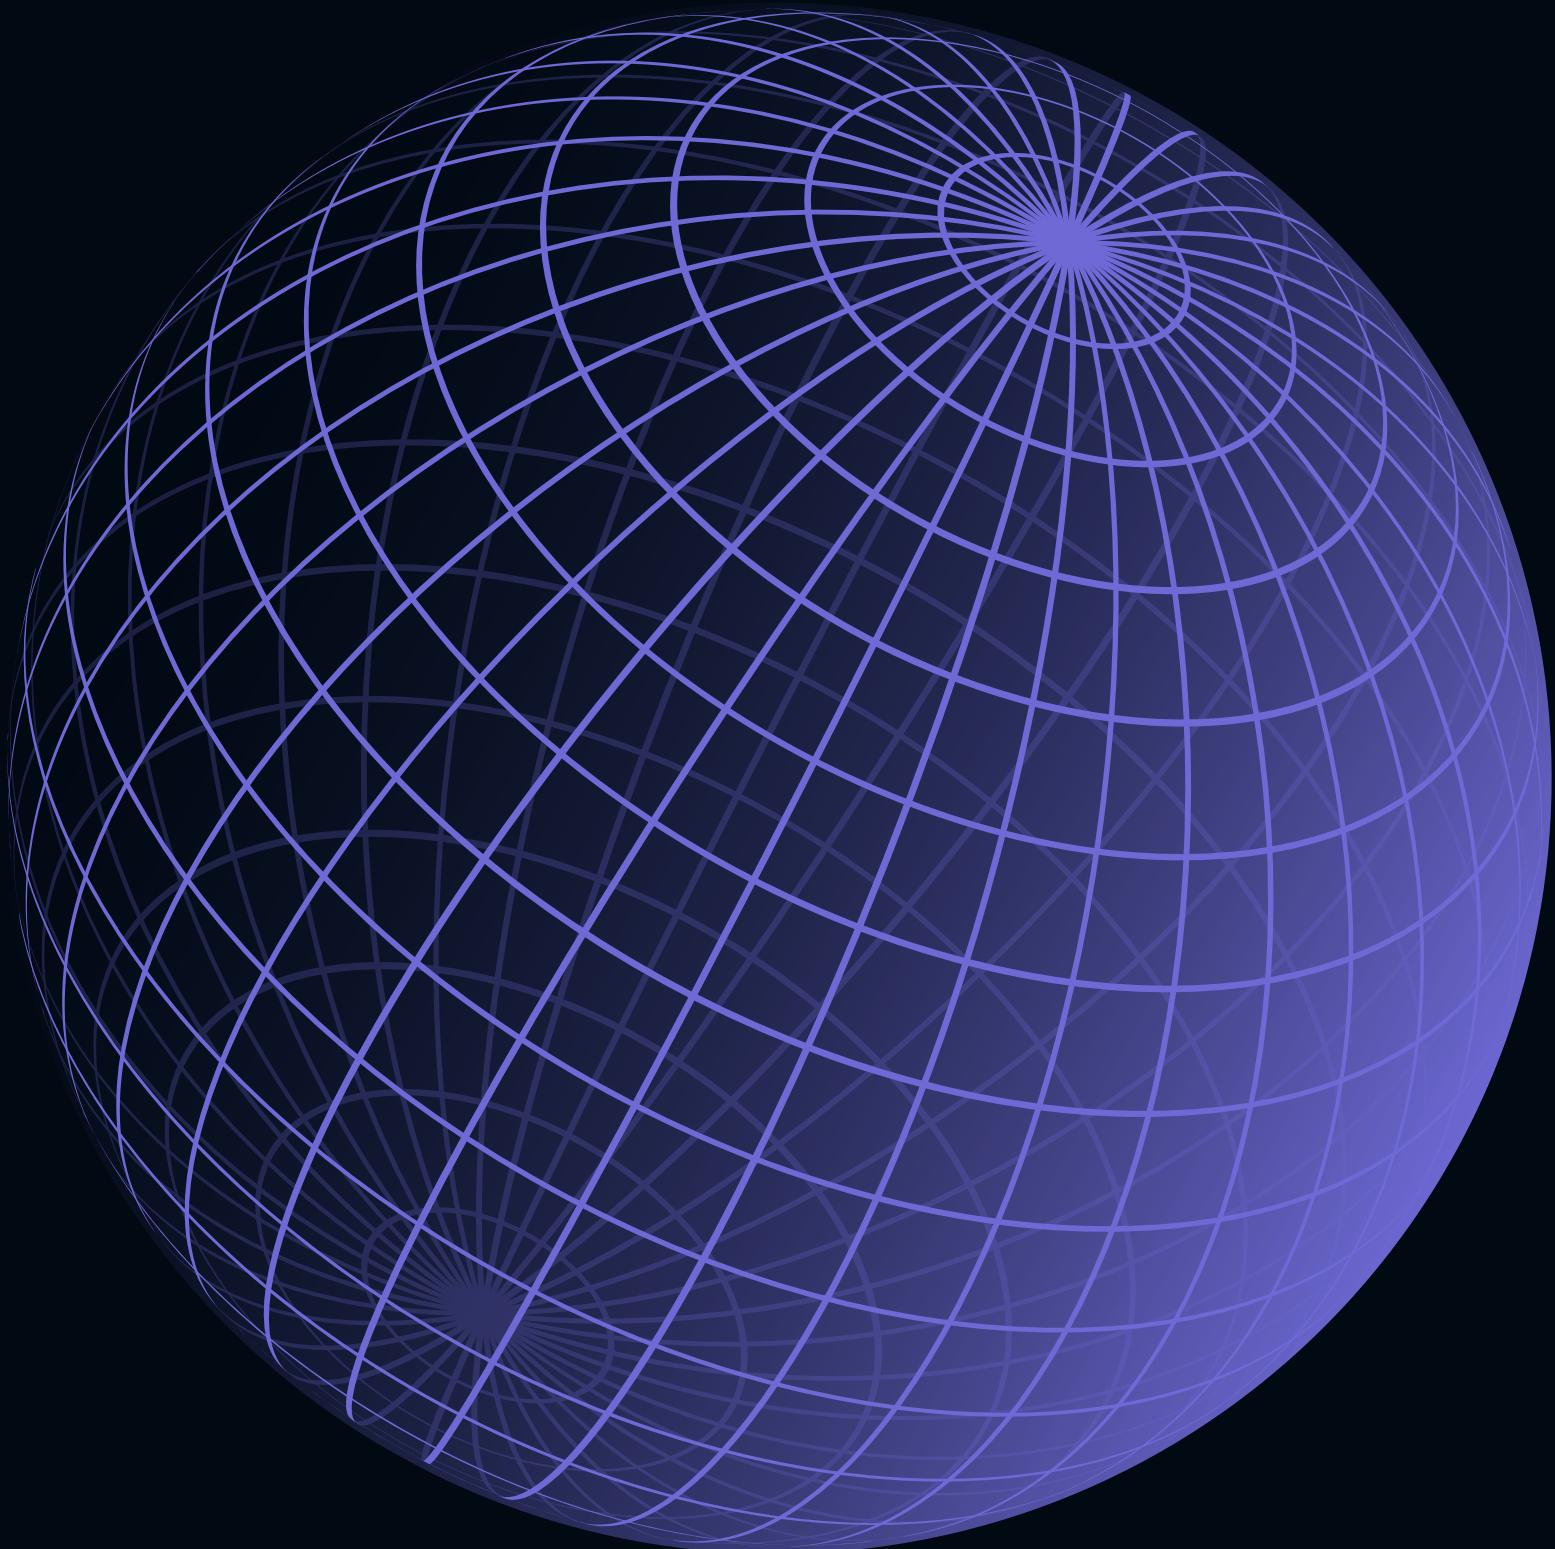
JOSÉ VINICIUS DE SANTANA SOUZA

VICTOR GABRIEL DE CARVALHO



SUMÁRIO

O que mostraremos hoje

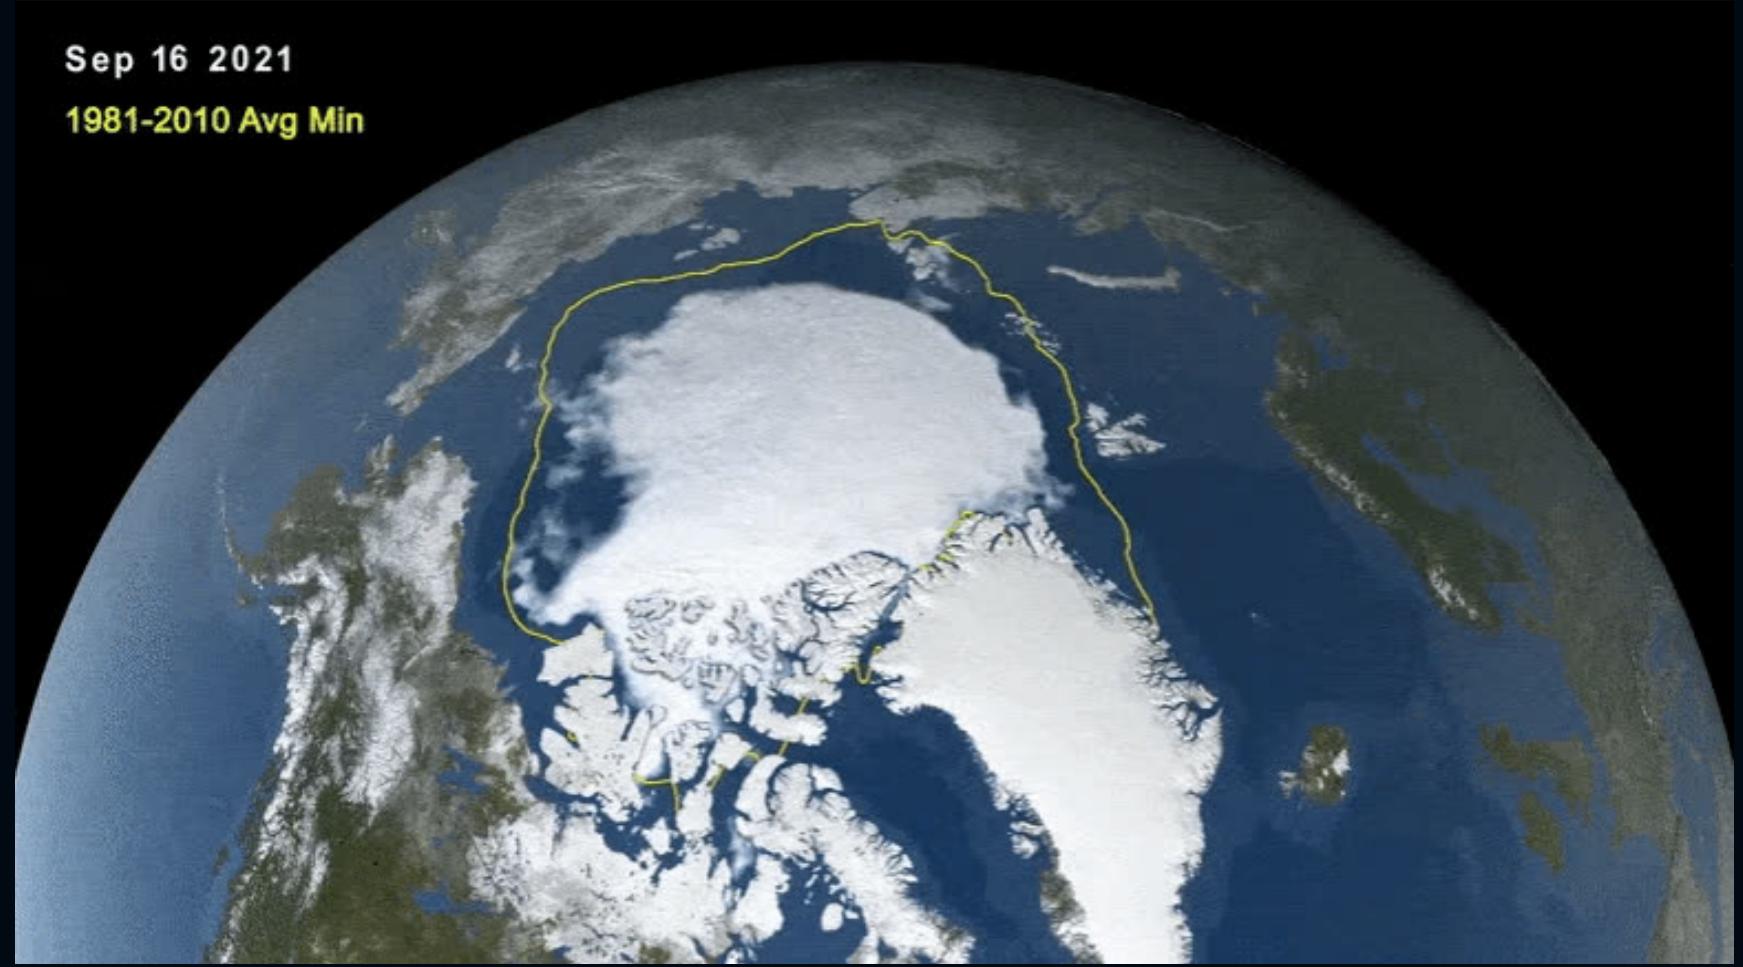


- Introdução
- Objetivos
- Justificativa
- Metodologia
- Dataset
- Modelos
- Otimizações
- Análises
- Conclusões

INTRODUÇÃO

Uma breve explicação do contexto

O gelo polar cobre cerca de 10% da superfície da Terra e representa quase 70% de toda a água doce. Perante isto, é inegável que as regiões polares desempenham um papel fundamental no clima e no sistema socioeconómico da Terra.



OBJETIVOS

UNET

Construir um sistema de segmentação de imagens baseado em UNet.

SEGMENTAÇÃO

Segmentar com precisão os pedaços de gelo observados do espaço, com foco particular em distinguir interfaces complexas entre gelo e água.

DESEMPENHO

Melhorar o desempenho do modelo explorando e avaliando várias técnicas de otimização em conjunto com métodos de ensemble.

JUSTIFICATIVA

Por que decidimos fazer esse trabalho?

Diante do nosso contexto é absolutamente necessário fornecer informações precisas e confiáveis sobre a localização, tamanho e extensão do gelo marinho.

Acreditamos que o nosso projeto pode tanto tornar as alterações climáticas um problema mais rastreável como mostrar o impacto dos métodos de otimização nos resultados de um modelo.



METODOLOGIA E EXPERIMENTAÇÃO

Como o projeto foi feito, testado e avaliado?





DATASET

LEEDS SCIML SEA ICE SEGMENTATION

KAGGLE COMPETITION

Este artigo se baseará no conjunto de dados da competição Leeds SciML Sea Ice Segmentation no Kaggle, cujo objetivo principal é gerar uma imagem segmentada de gelo marinho.

ESTRUTURA E COMPOSIÇÃO DO DATASET

O conjunto de dados é composto inteiramente por imagens “.tiff”. Cada amostra de dados é separada em três arquivos de imagem:

- VIS
- SAR
- REF

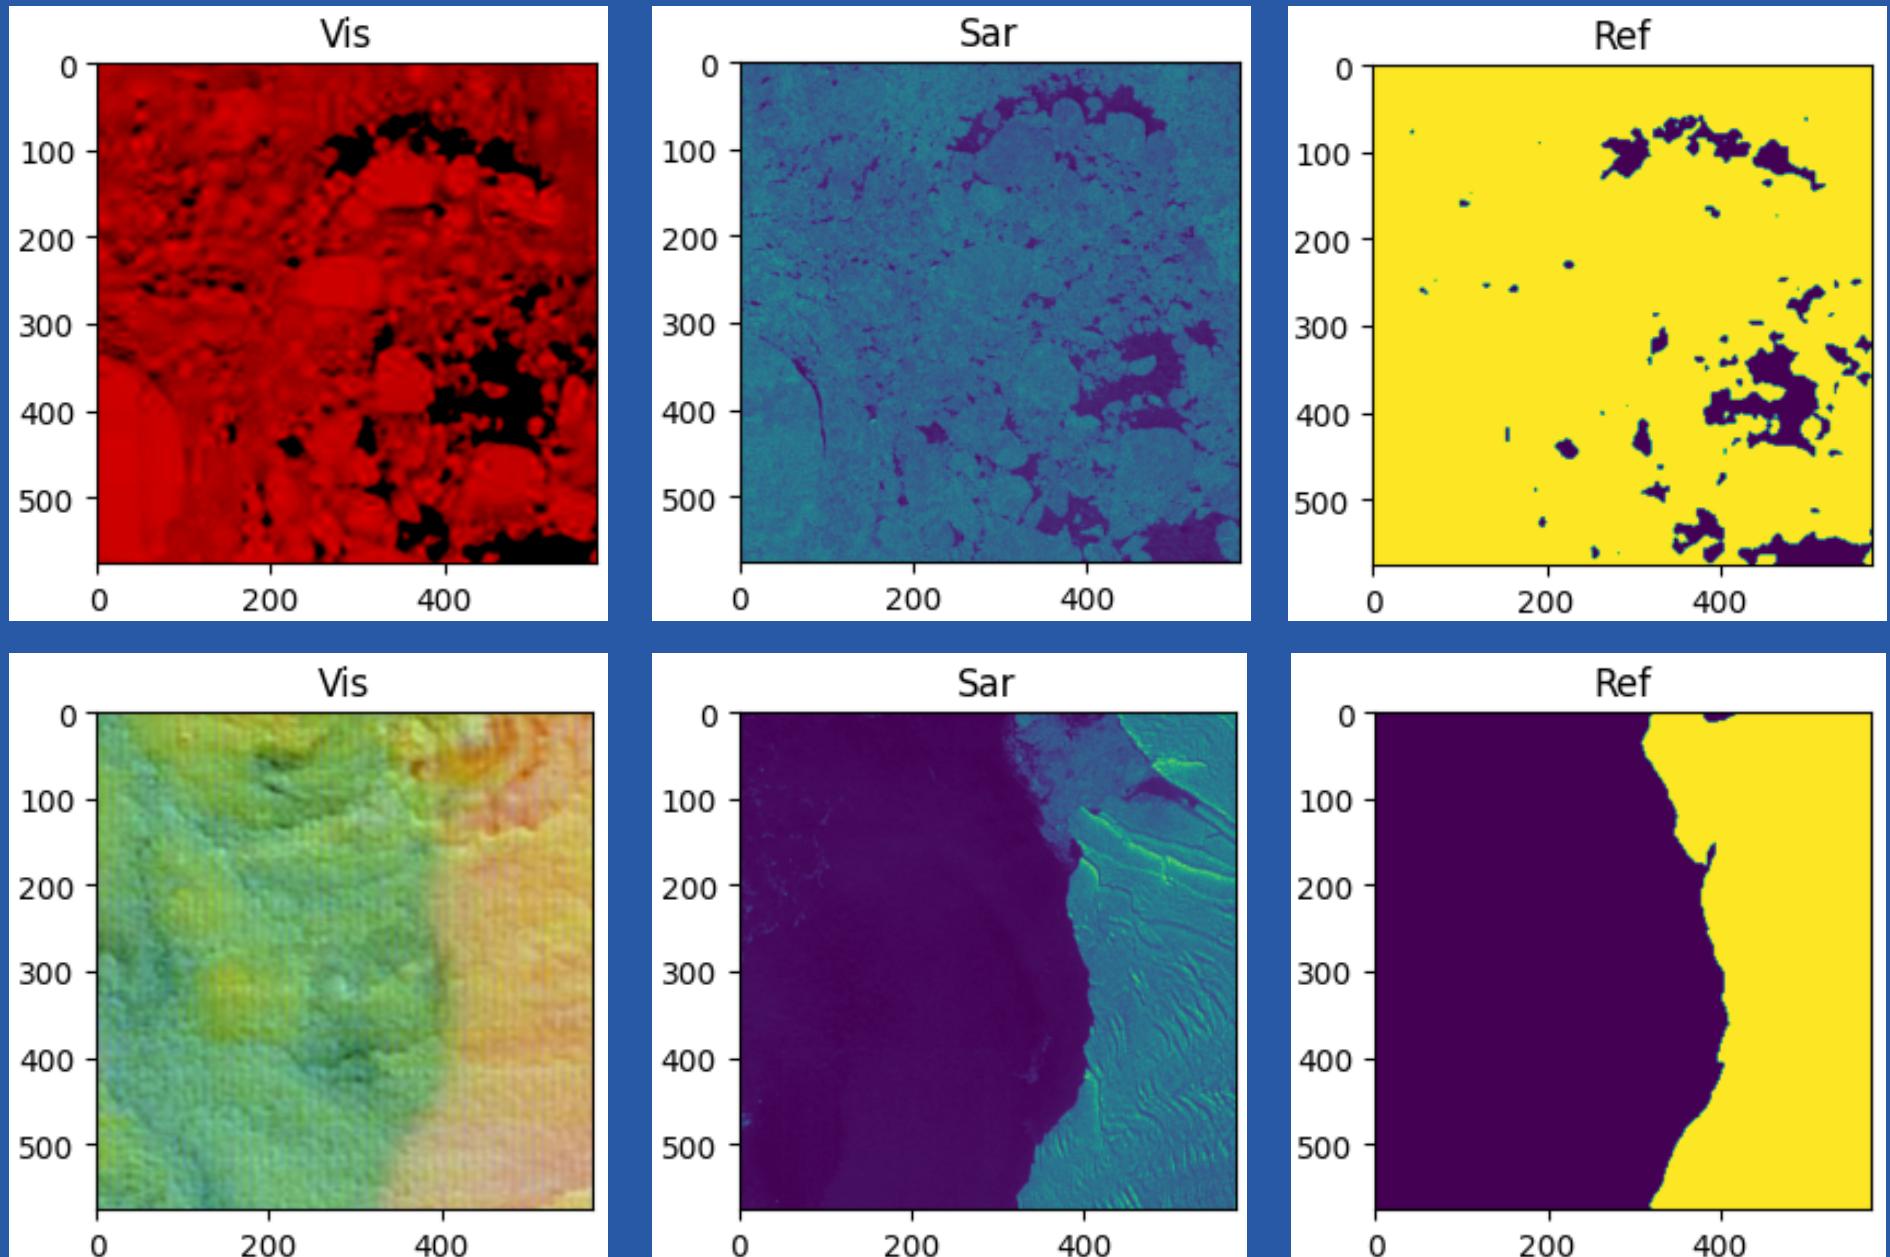
DATASET

LEEDS SCIML SEA ICE SEGMENTATION

ANÁLISE EXPLORATÓRIA DOS DADOS

O dataset é originalmente dividido em dois diretórios, um para treinamento (com 4221 arquivos, ou 1407 amostras) e um para testes (com 704 arquivos, ou 352 amostras).

As imagens VIS e REF tem resolução de 240x240, enquanto a SAR possui 720x720.



DATASET

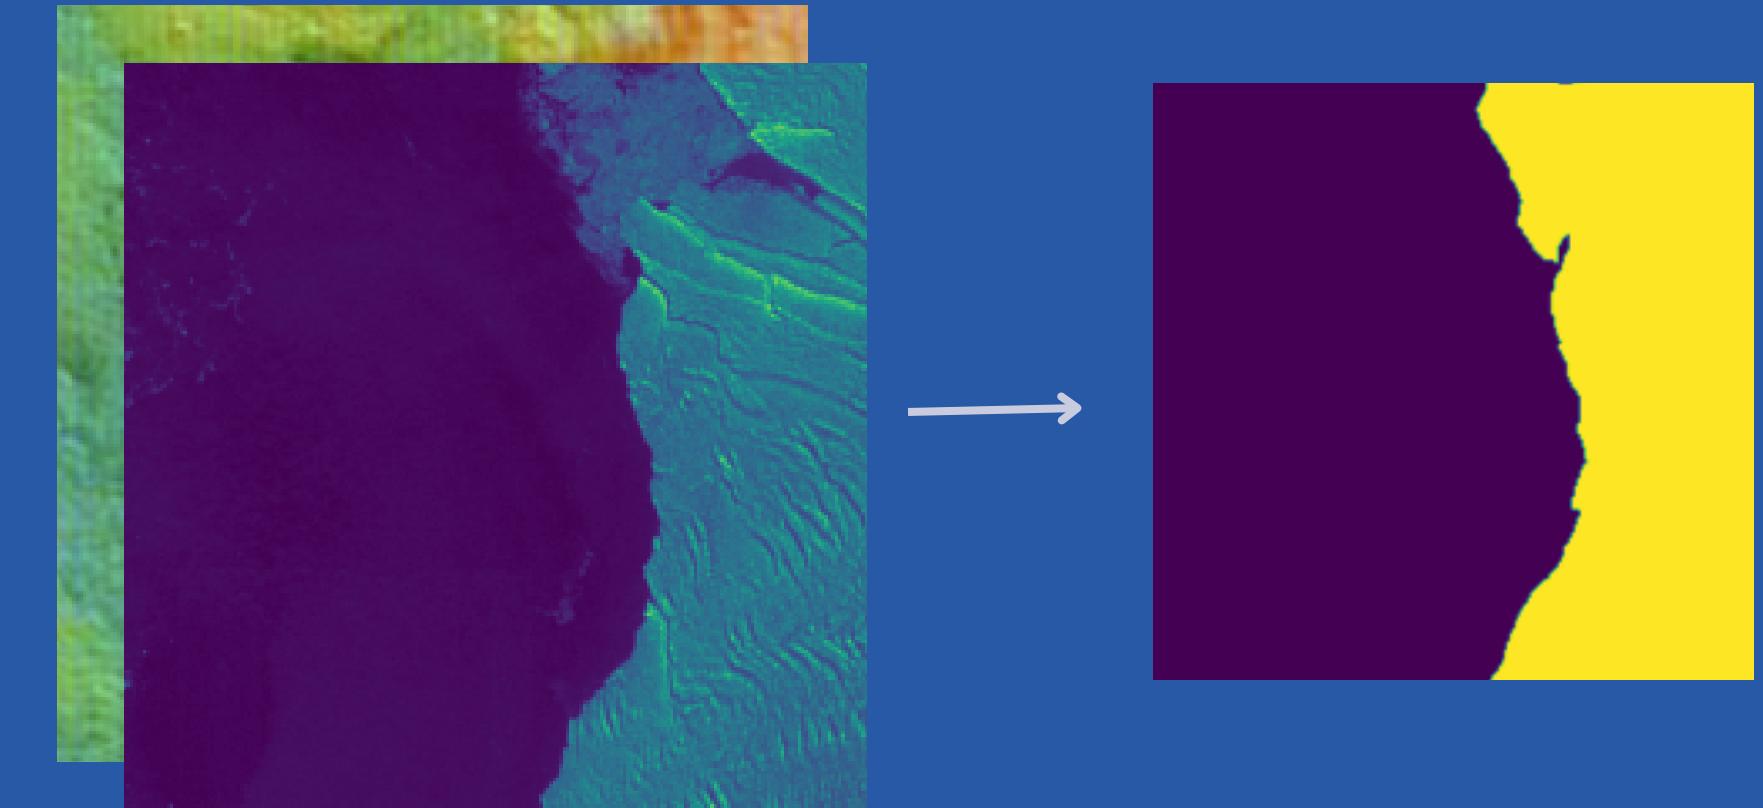
LEEDS SCIML SEA ICE SEGMENTATION

DEFINIÇÕES DE TREINAMENTO

Os códigos foram projetados para rodar em até 4GB de VRAM. Para isso, as imagens foram padronizadas para a resolução de 384x384 e o tamanho do BATCH foi definido para 2 amostras.

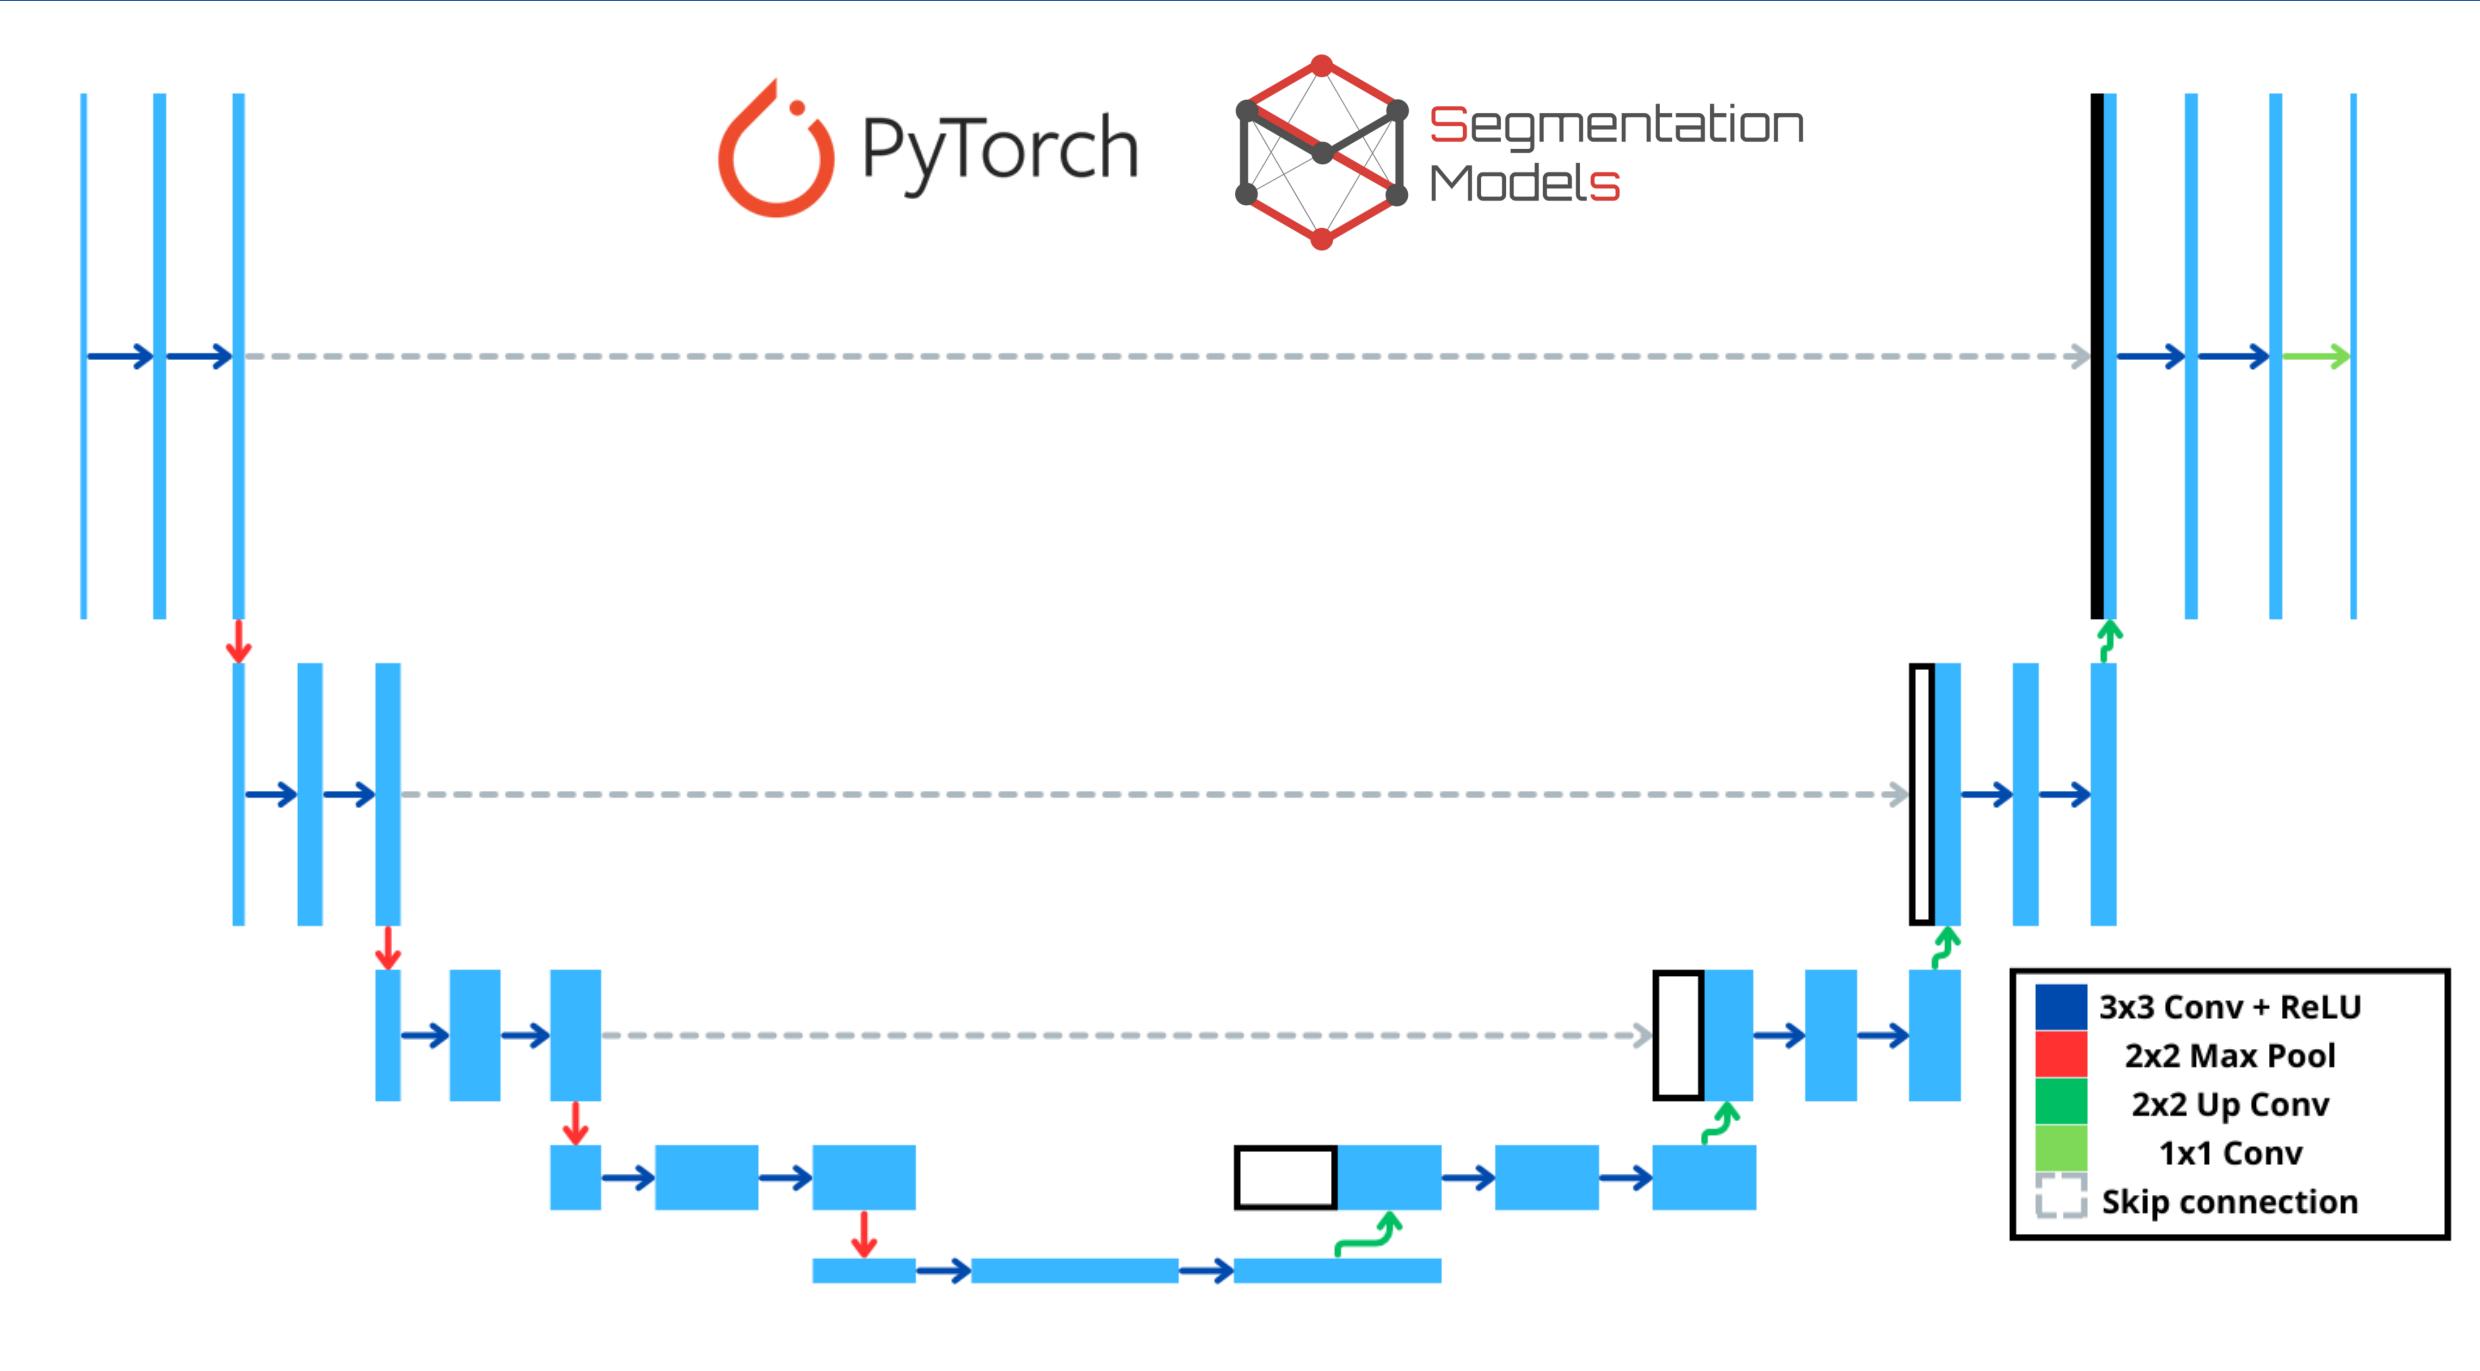
Para a entrada nos modelos, as images VIS e SAR foram concatenadas, resultando em uma imagem de 4 canais.

Não foi feita nenhum augmentation, por motivos computacionais.



MODELOS

Para aprender com os dados, será usado um modelo UNet. É uma das abordagens mais populares para segmentação de imagens, combinando a eficiência de redes neurais convolucionais e links residuais. Além do modelo implementado por nós, foi utilizado um modelo com encoder pré-treinado na Image Net



MODELOS

```
base_model = UNet(in_channels=4, out_channels=1).to(device)
loss_fn = nn.BCEWithLogitsLoss()
optimizer = torch.optim.Adam(base_model.parameters(), lr=0.0001)

def train(model, train_loader, val_loader, max_epochs, loss_fn, optimizer, patience=3, plot=True):
    max_epochs = 20
    train(base_model, train_loader, val_loader, max_epochs, loss_fn, optimizer)
```

Para aprender com os dados, será usado um modelo UNet. É uma das abordagens mais populares para segmentação de imagens, combinando a eficiência de redes neurais convolucionais e links residuais.

Além do modelo implementado por nós, foi utilizado um modelo com encoder pré-treinado na Image Net

HYPERPARAMETER TUNING

Para um ajuste automático de hiperparâmetros, foi utilizado o Optuna Framework que emprega uma série de algoritmos de otimização de última geração.

BAGGING

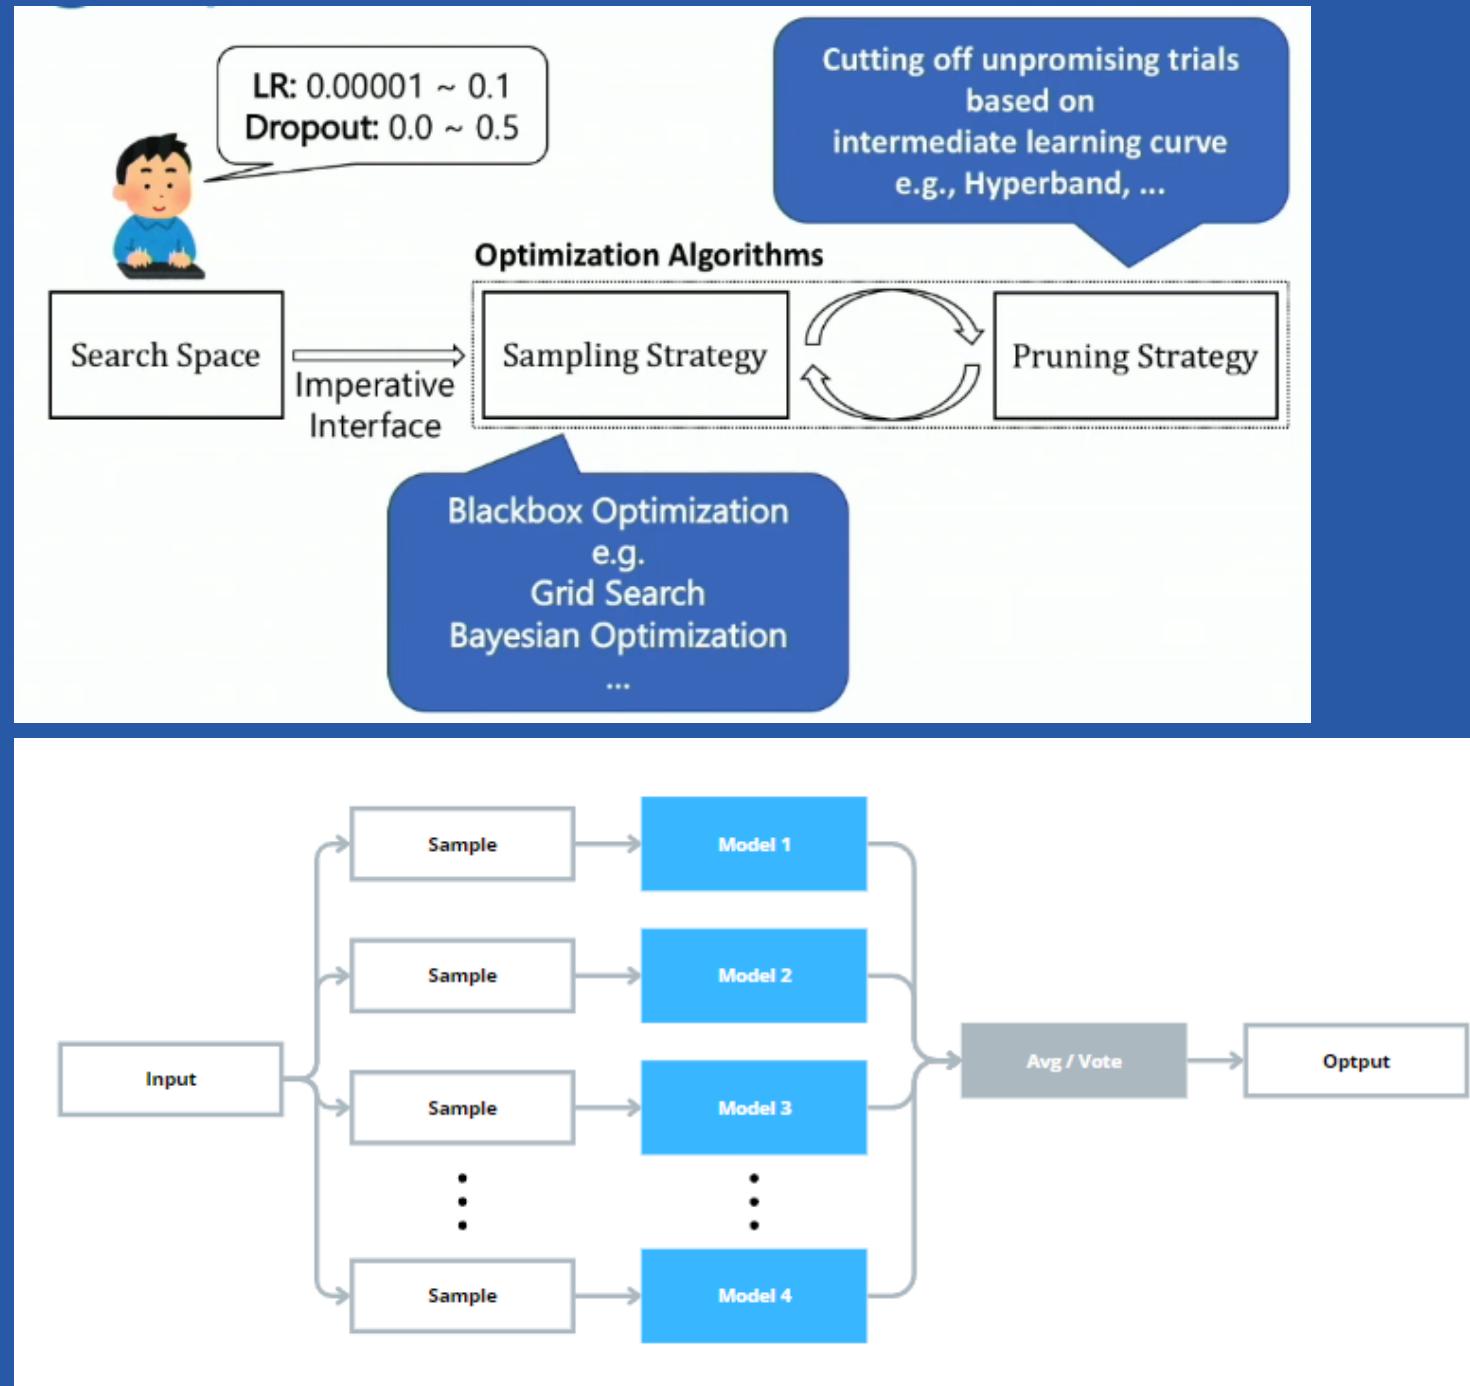
É o método de aprendizagem em conjunto que consiste em treinar múltiplas instâncias do mesmo algoritmo de aprendizagem em diferentes subconjuntos de dados de treinamento. No final, todos os resultados são calculados ou votados para um resultado final.

TÉCNICAS DE OTIMIZAÇÃO

TÉCNICAS DE OTIMIZAÇÃO

HYPERPARAMETER TUNING

BAGGING

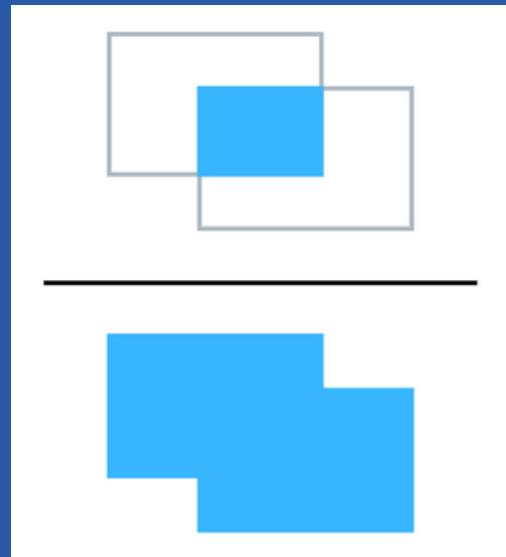


MÉTRICAS DE AVALIAÇÃO

Como saber qual variação é melhor?

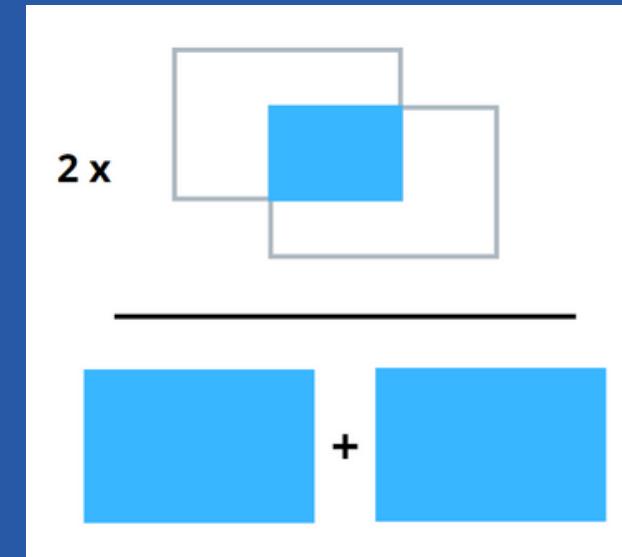
1

INTERSECTION OVER UNION



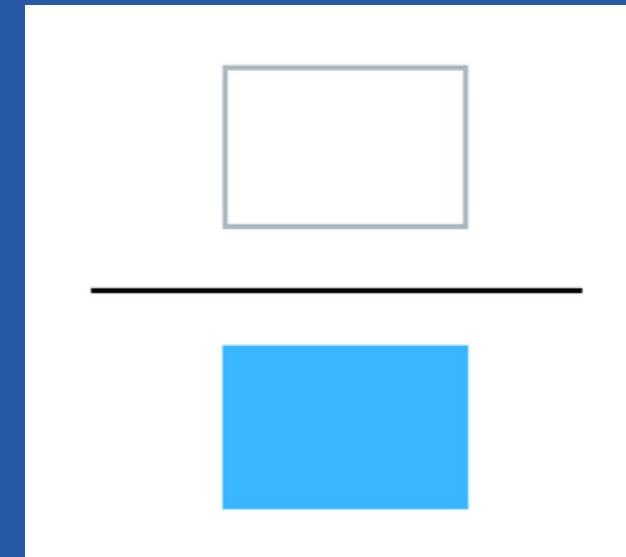
2

DICE COEFFICIENT



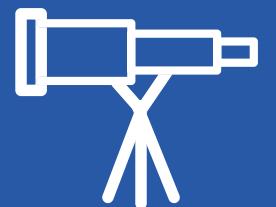
3

PIXEL ACCURACY



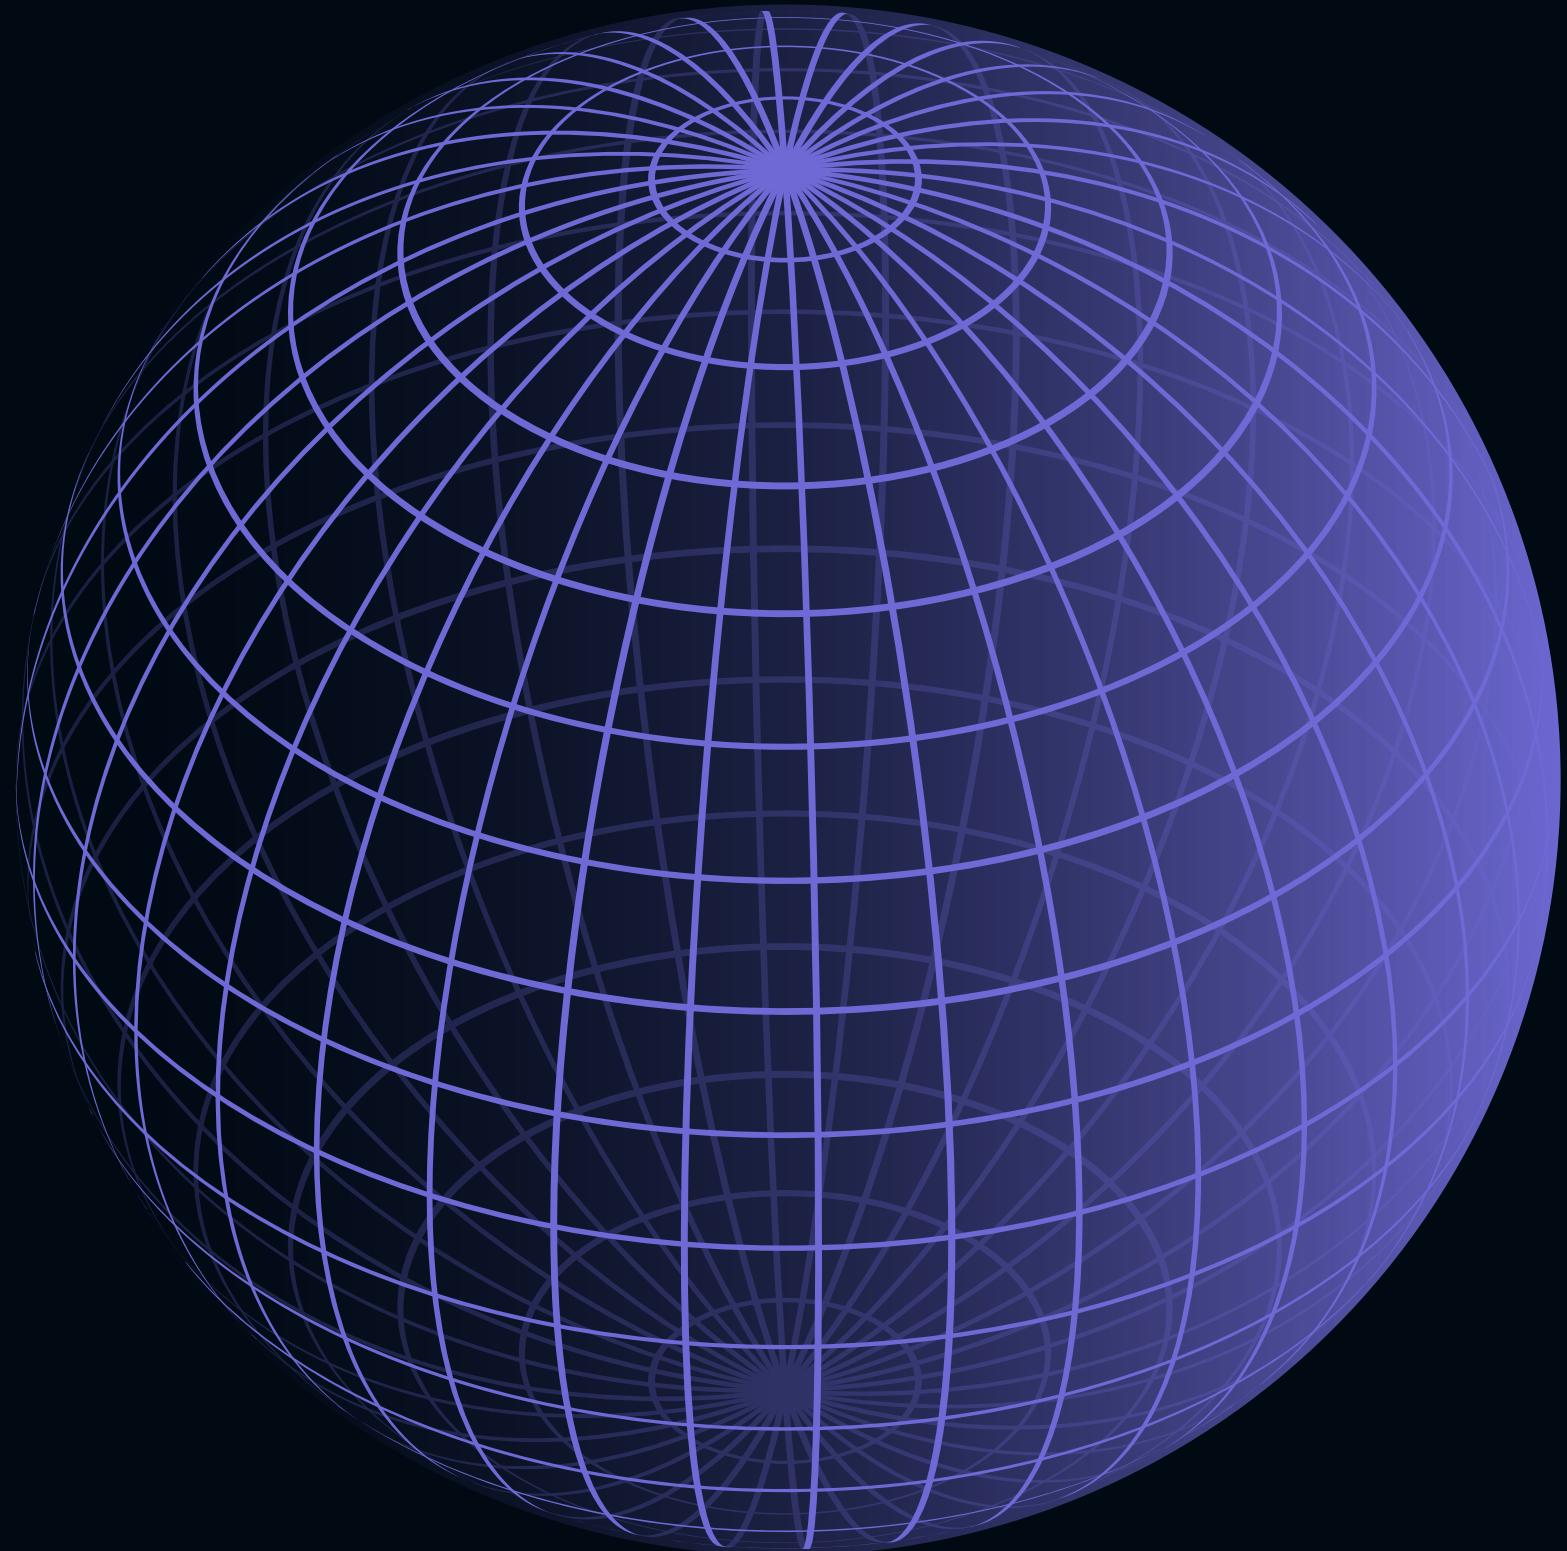
4

VISUALIZAÇÃO

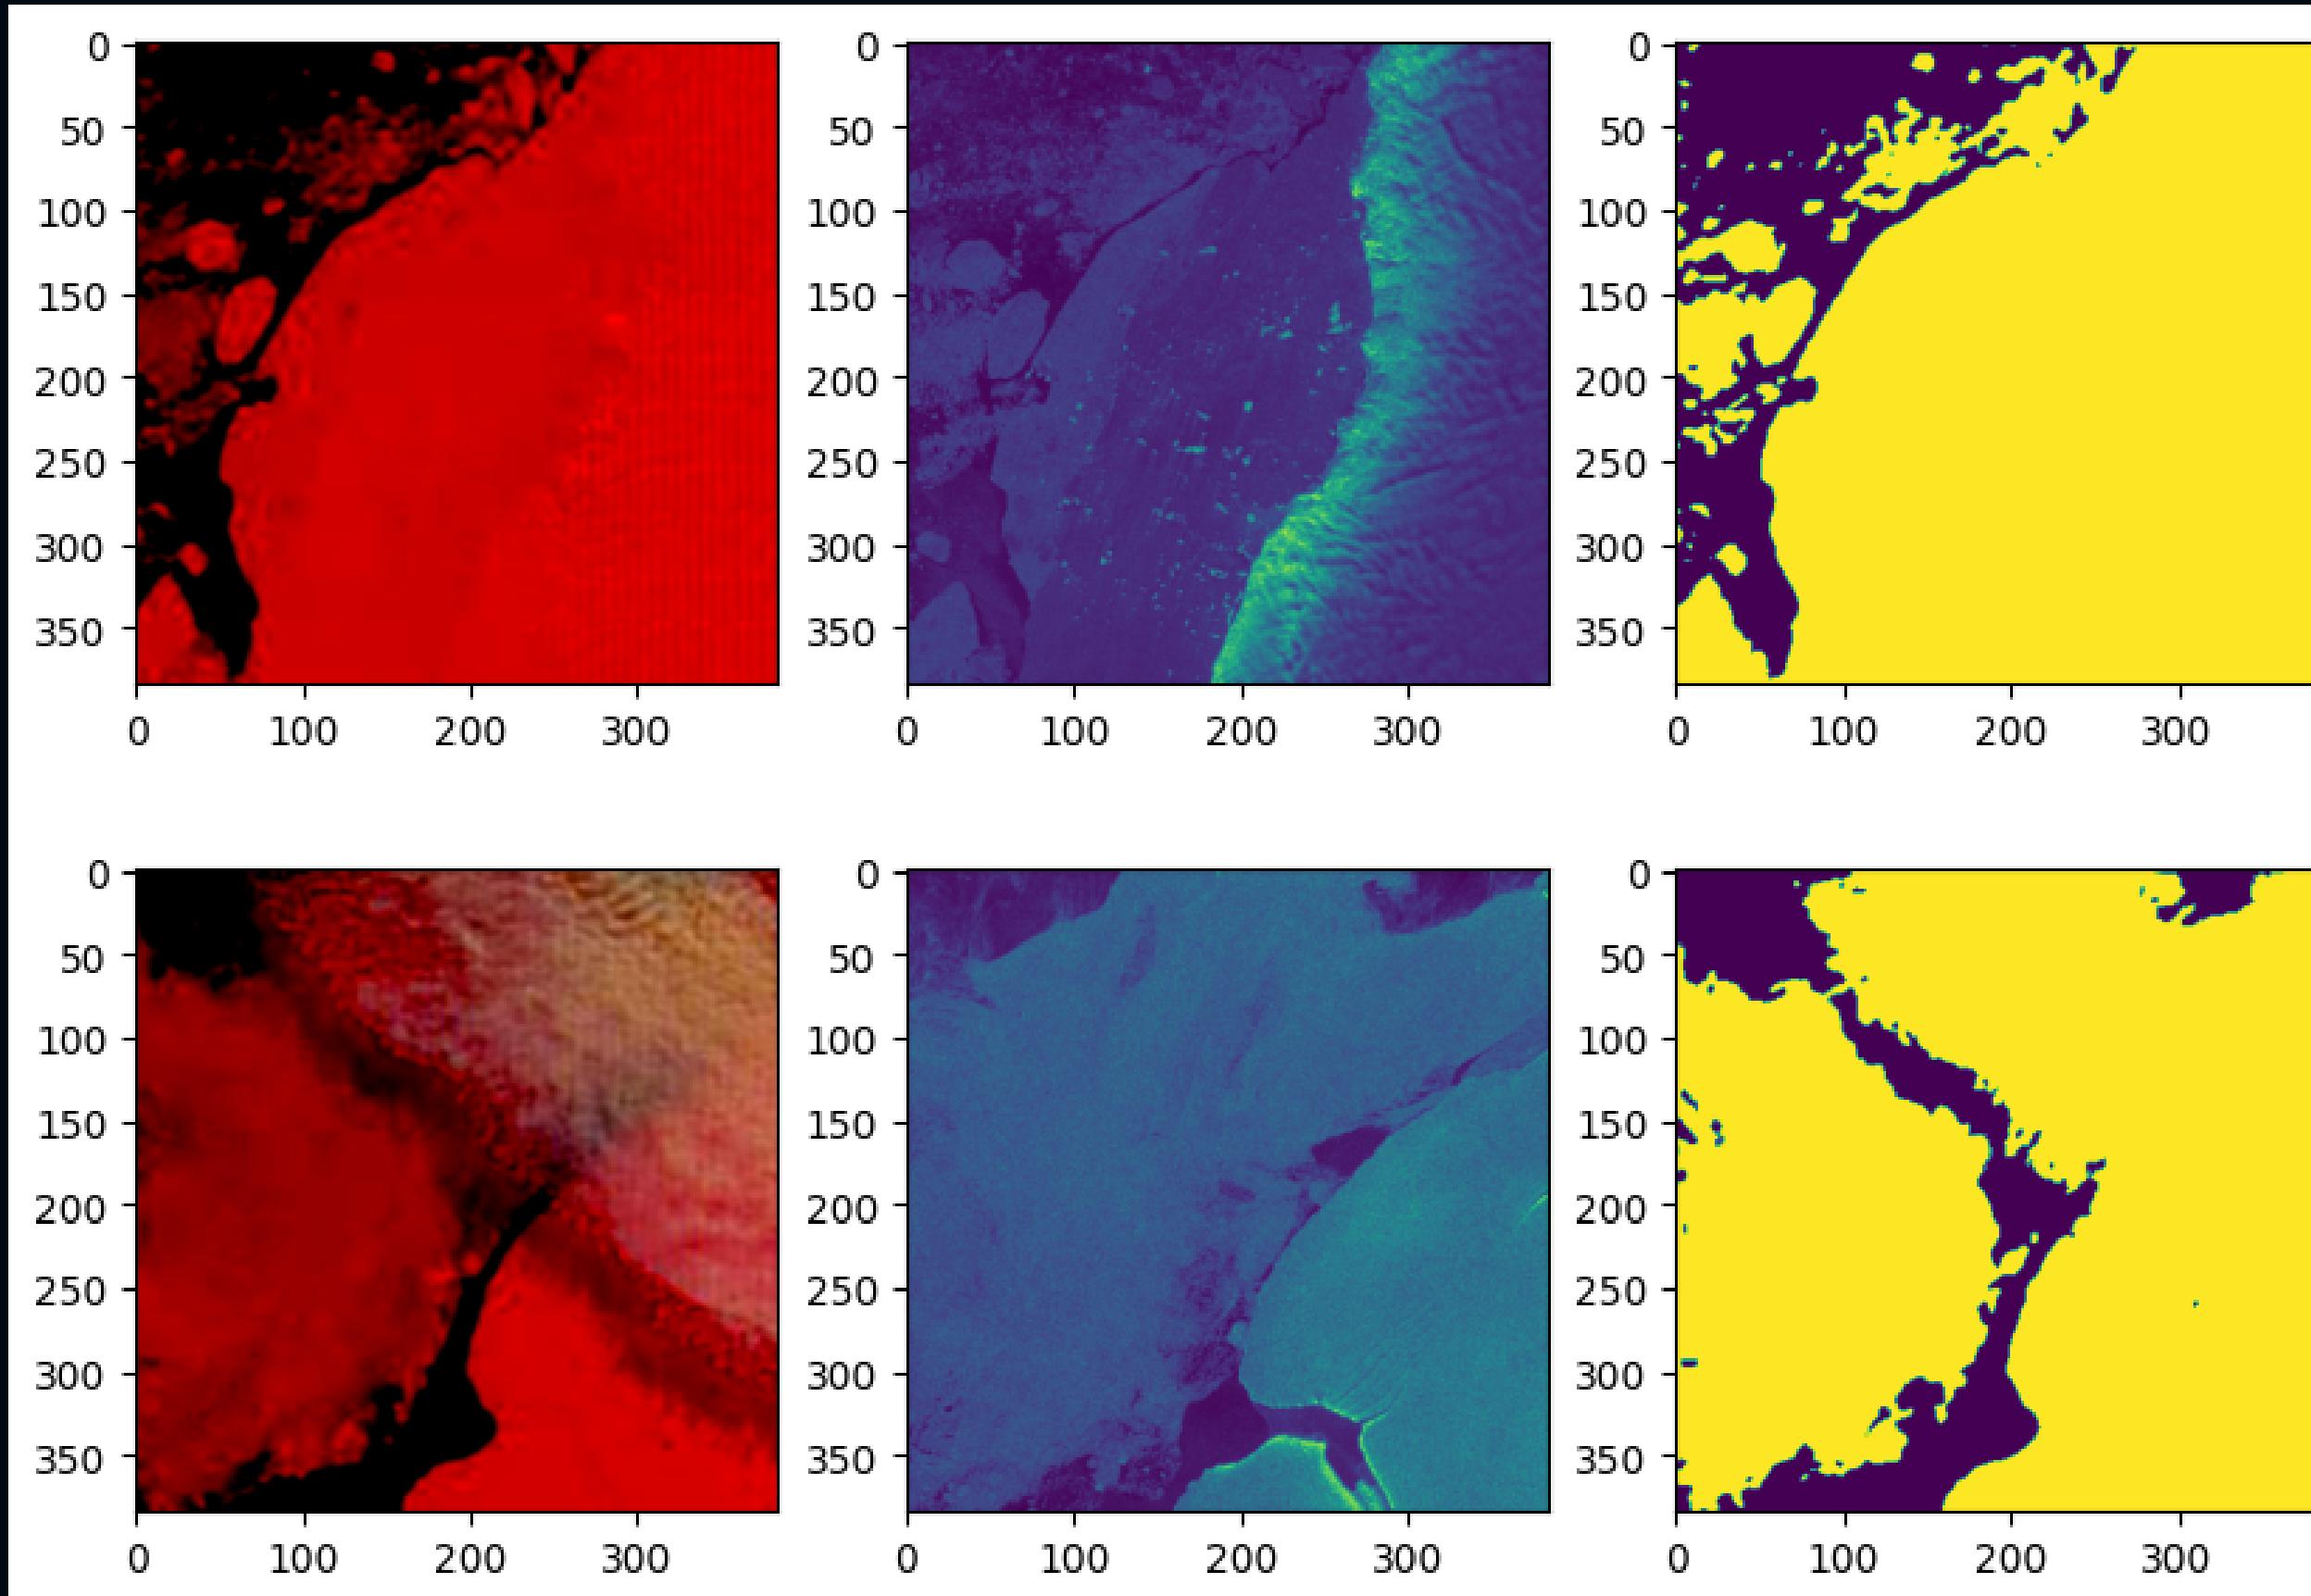


ANÁLISE DOS RESULTADOS

QUAL MODELO SE SAIU MELHOR?



017



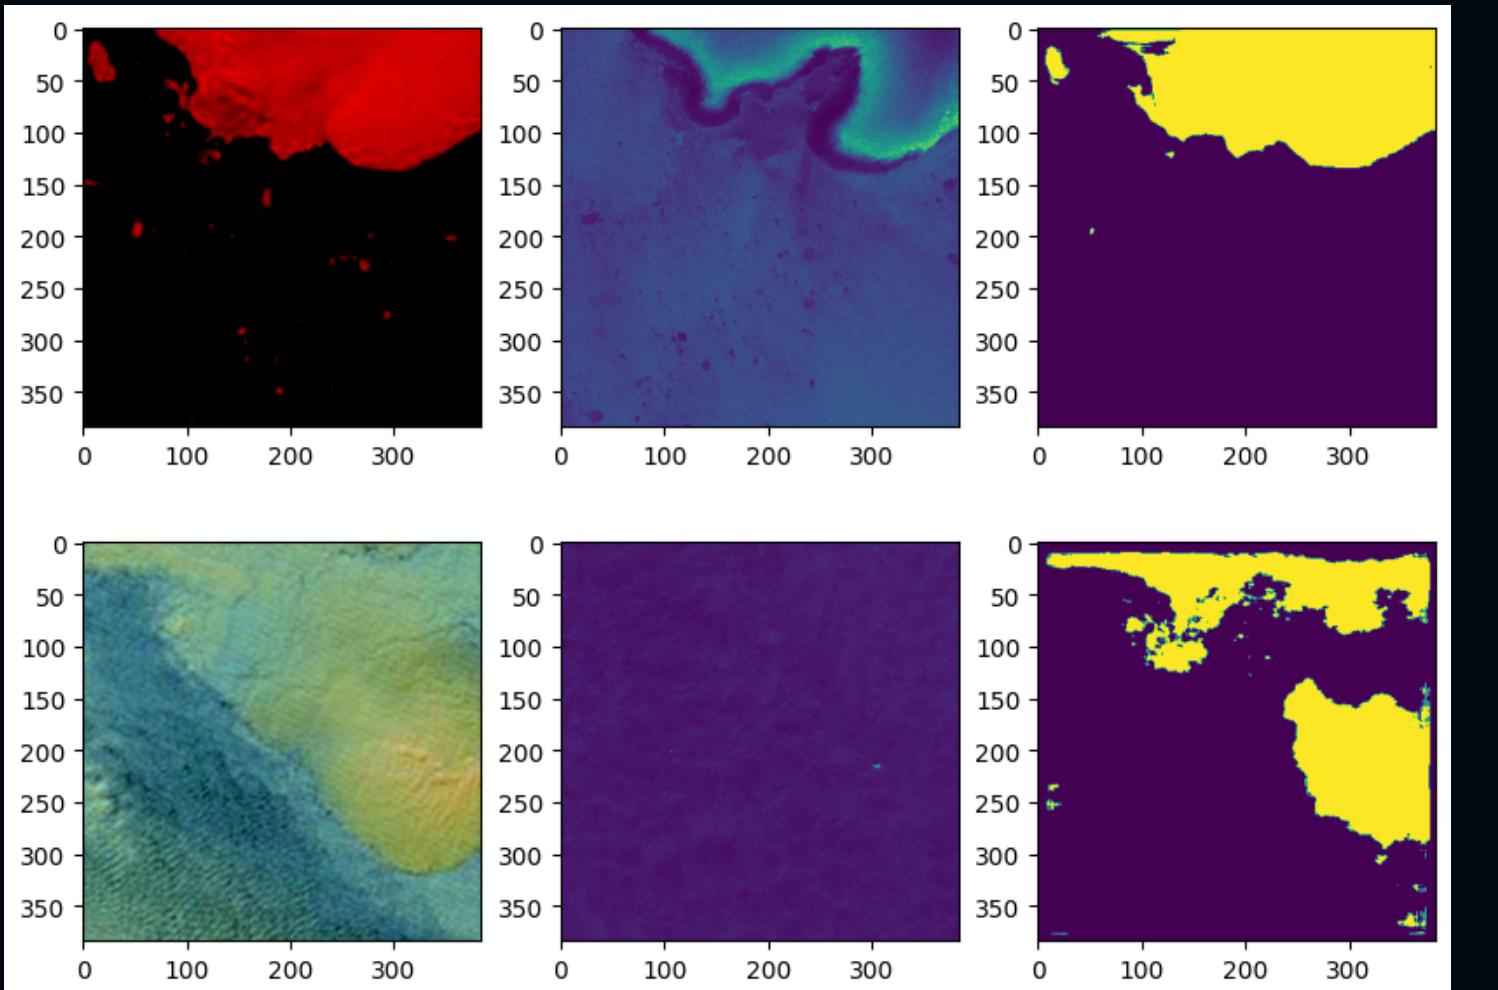
Modelo Base

IOU: 0.733

DICE: 0.807

Pixel Accuracy: 0.807

018

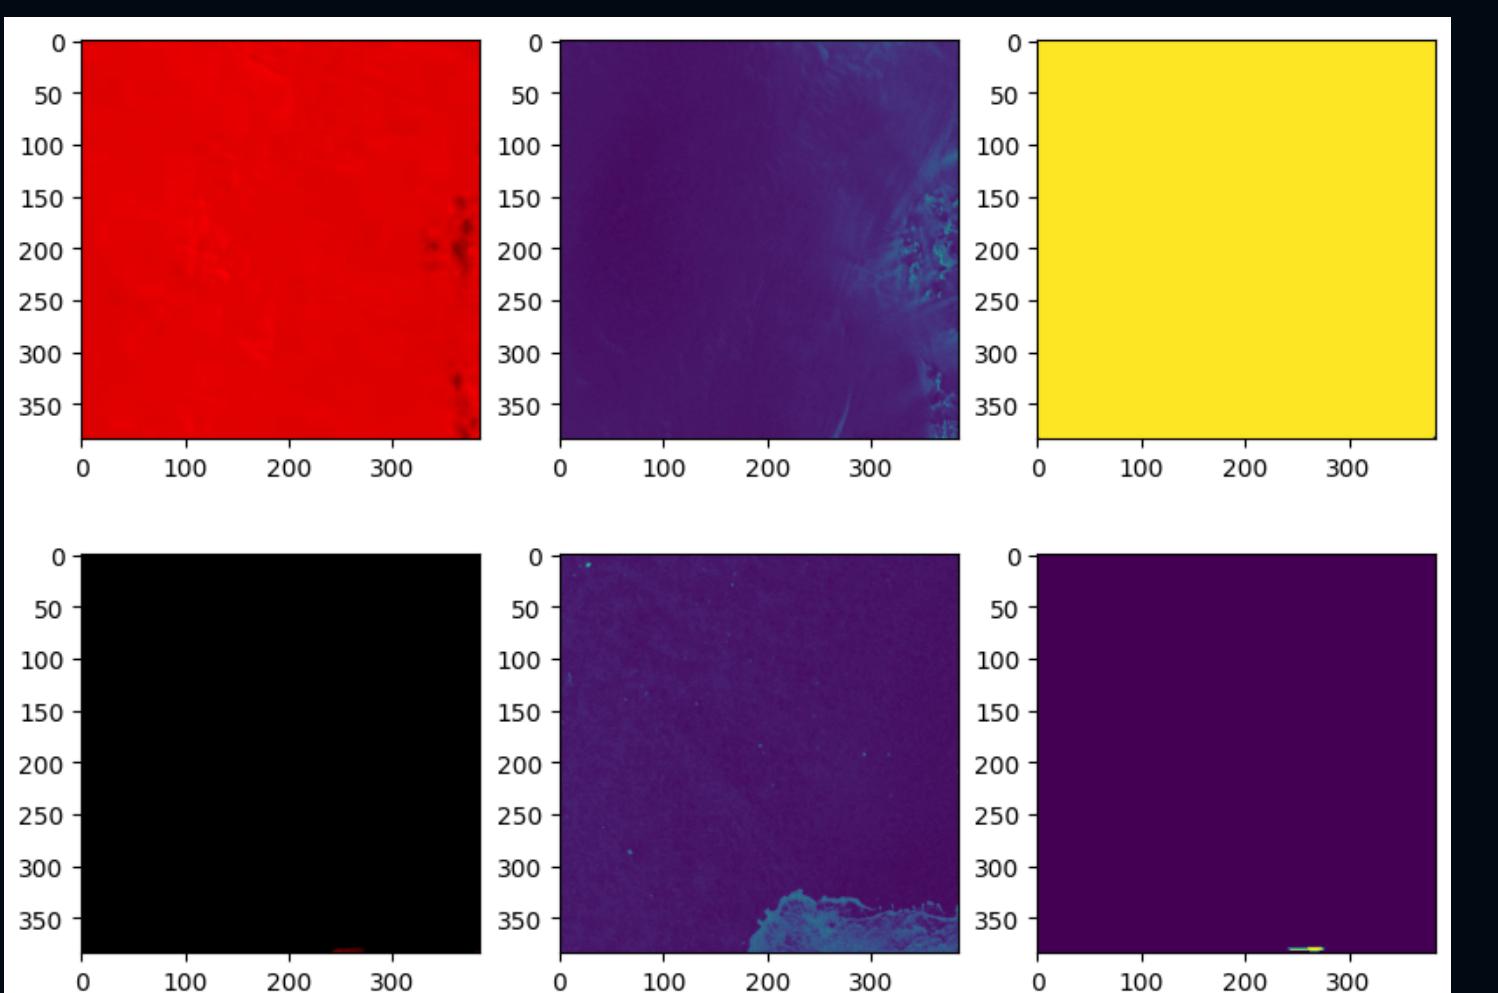


Modelo ResNet50

IOU: 0.706

DICE: 0.780

Pixel Accuracy: 0.765



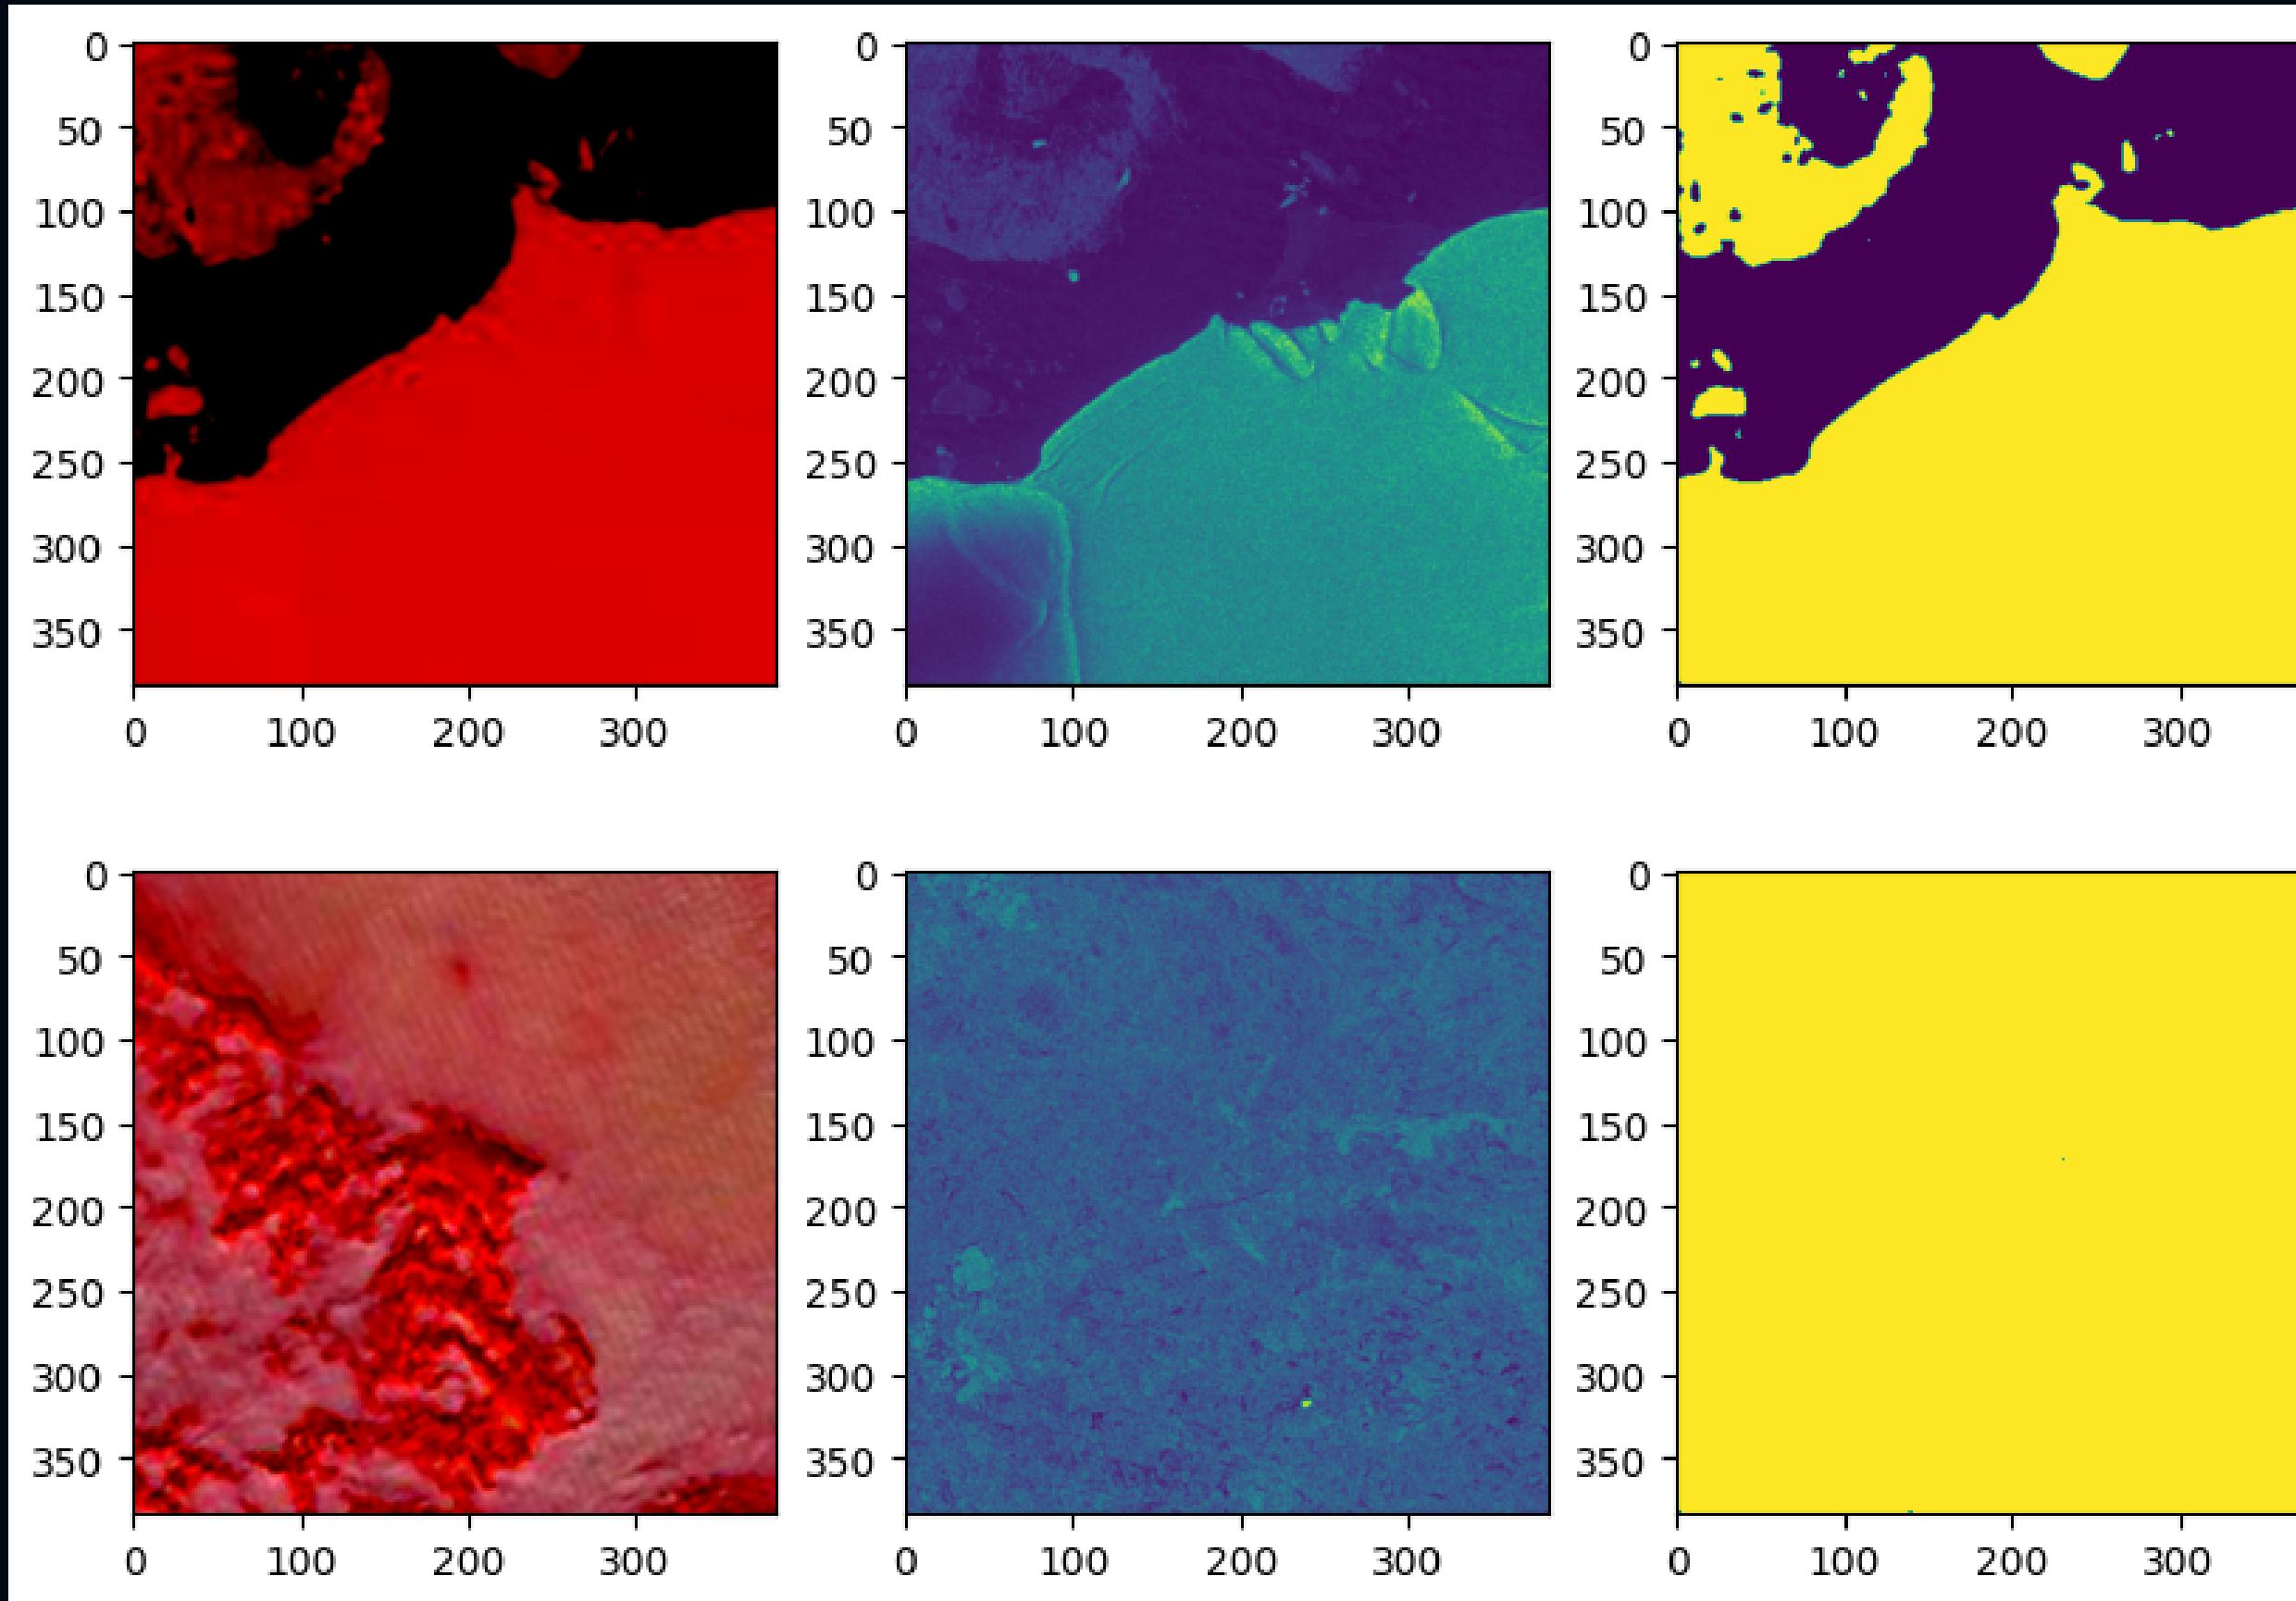
Modelo ResNet34

IOU: 0.688

DICE: 0.757

Pixel Accuracy: 0.737

019



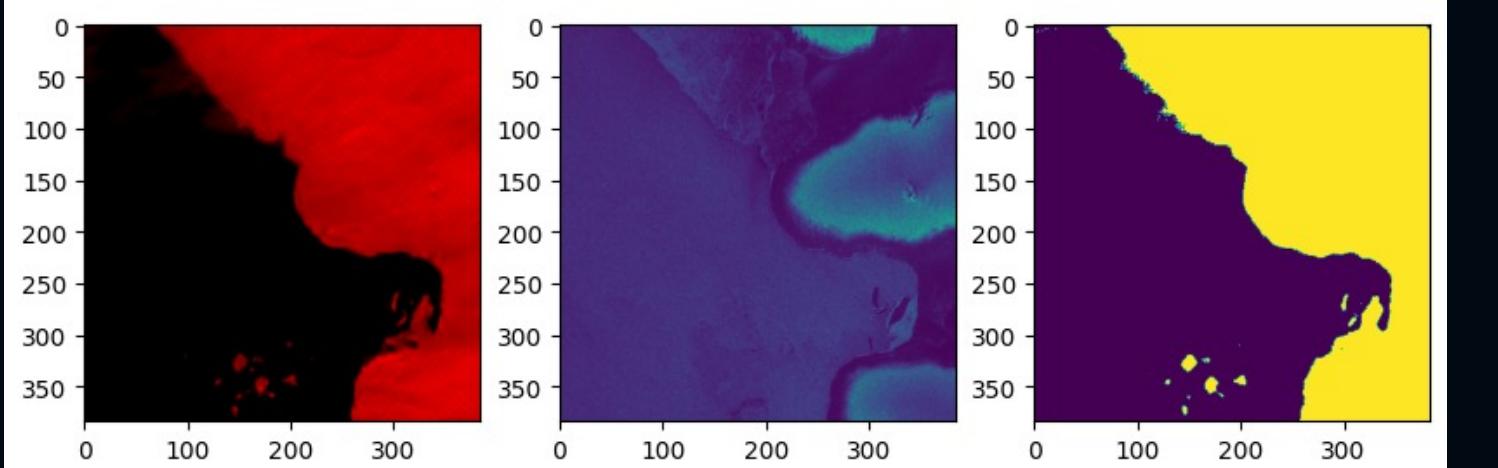
Modelo ResNet18

IOU: 0.772

DICE: 0.832

Pixel Accuracy: 0.878

020

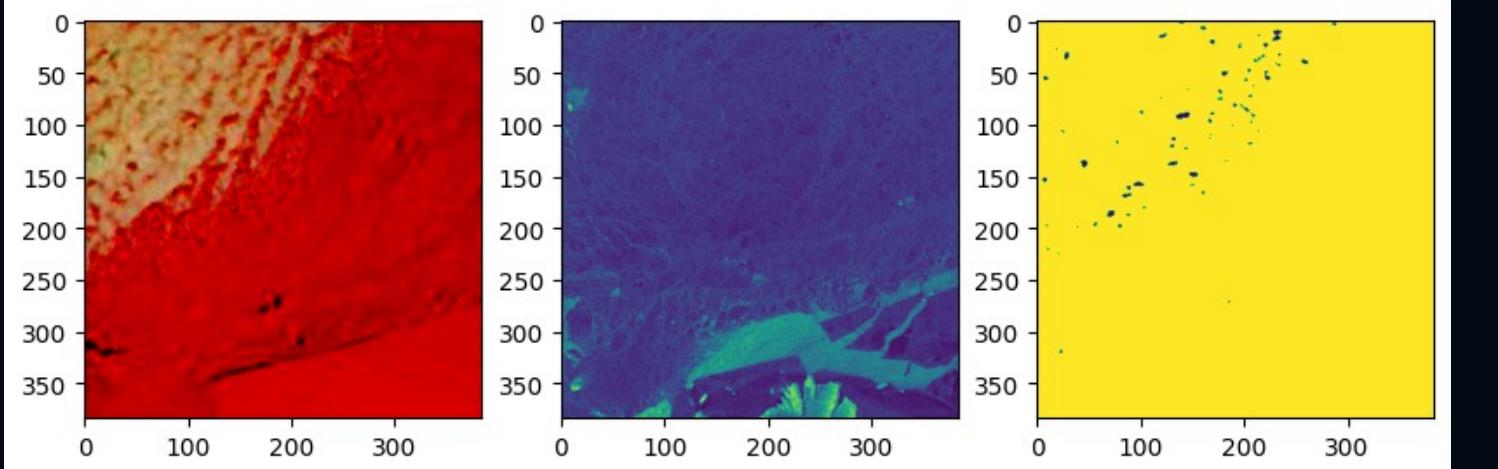


Optuna 1

IOU: 0.662

DICE: 0.746

Pixel Accuracy: 0.892

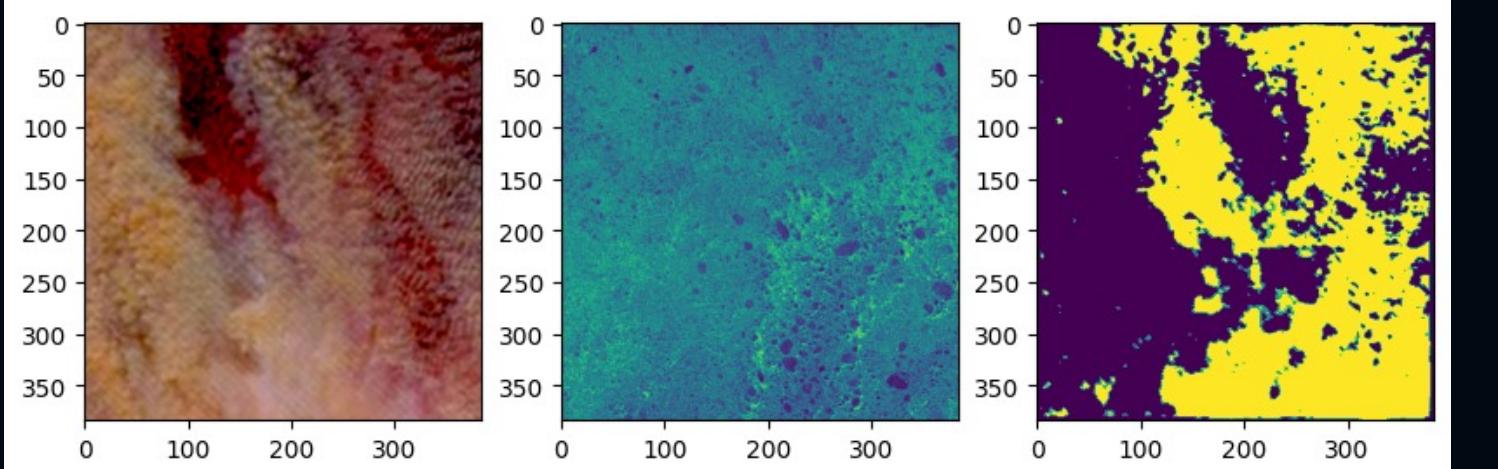


Optuna 2

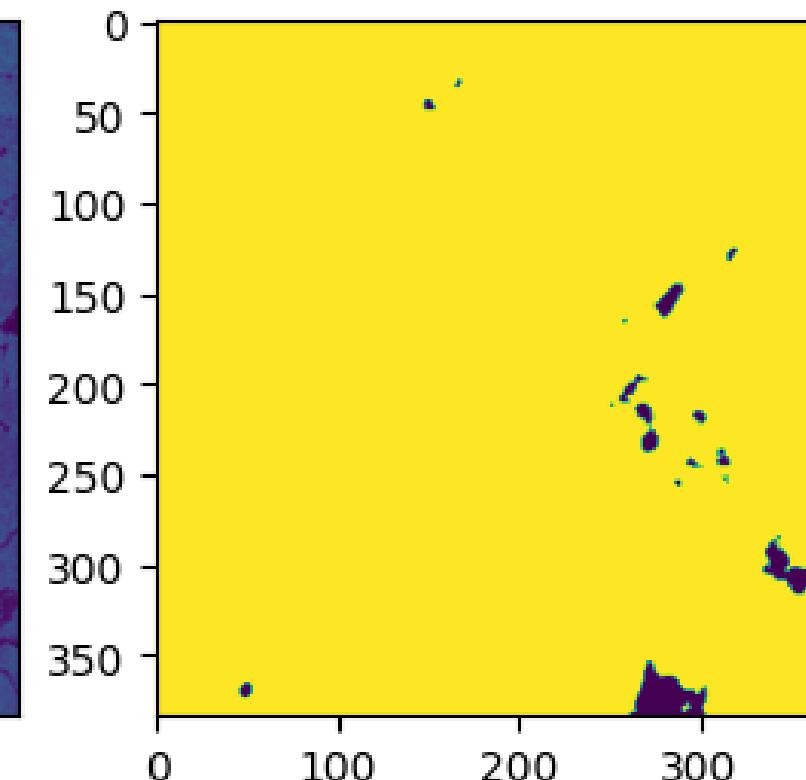
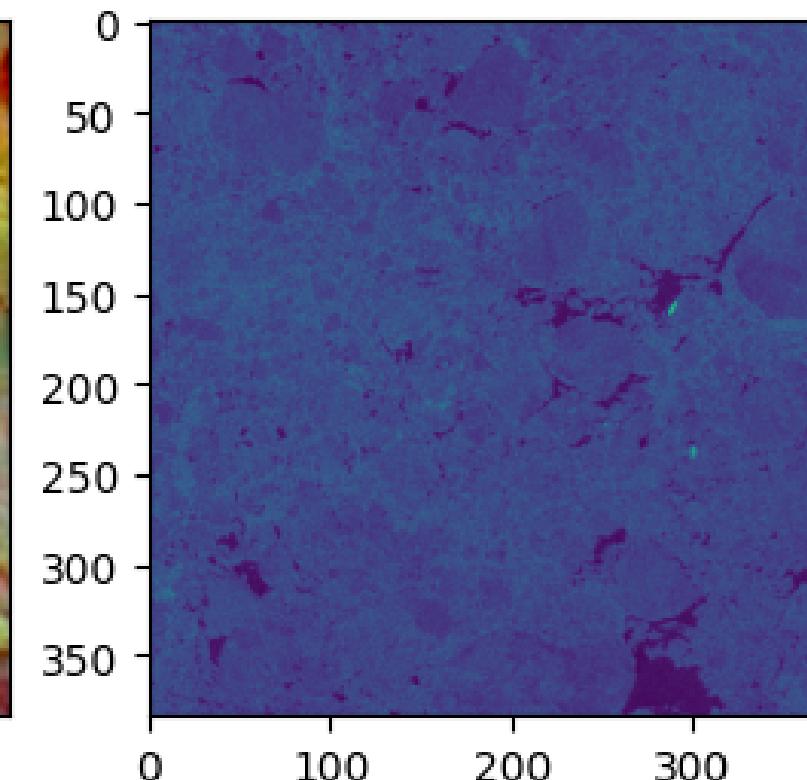
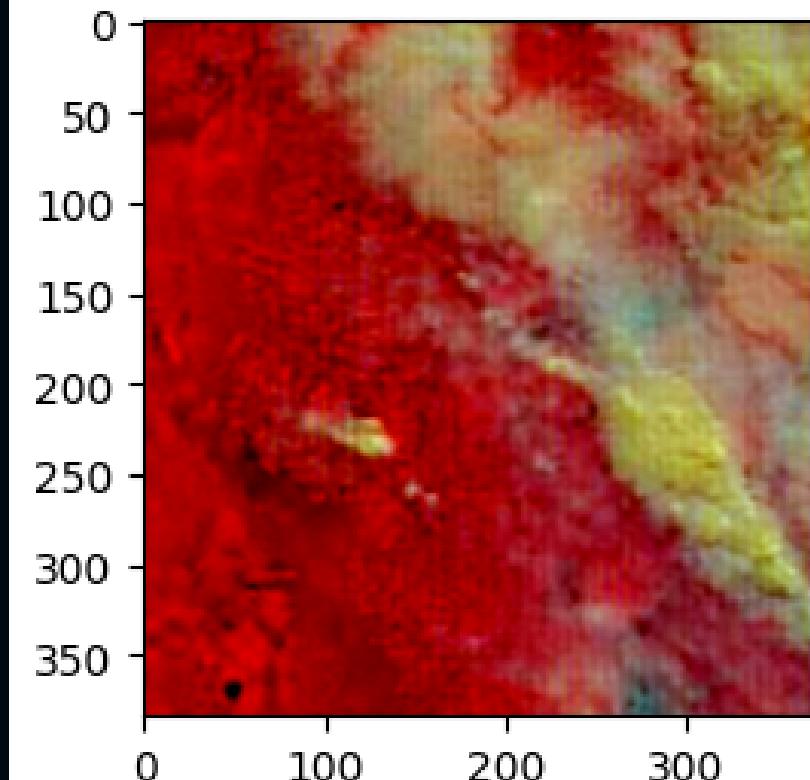
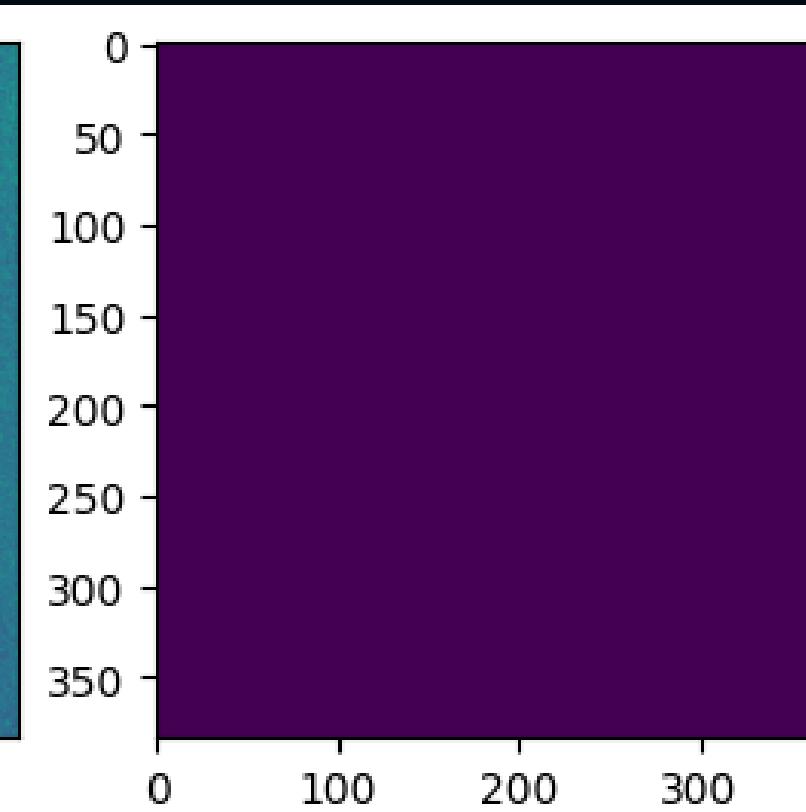
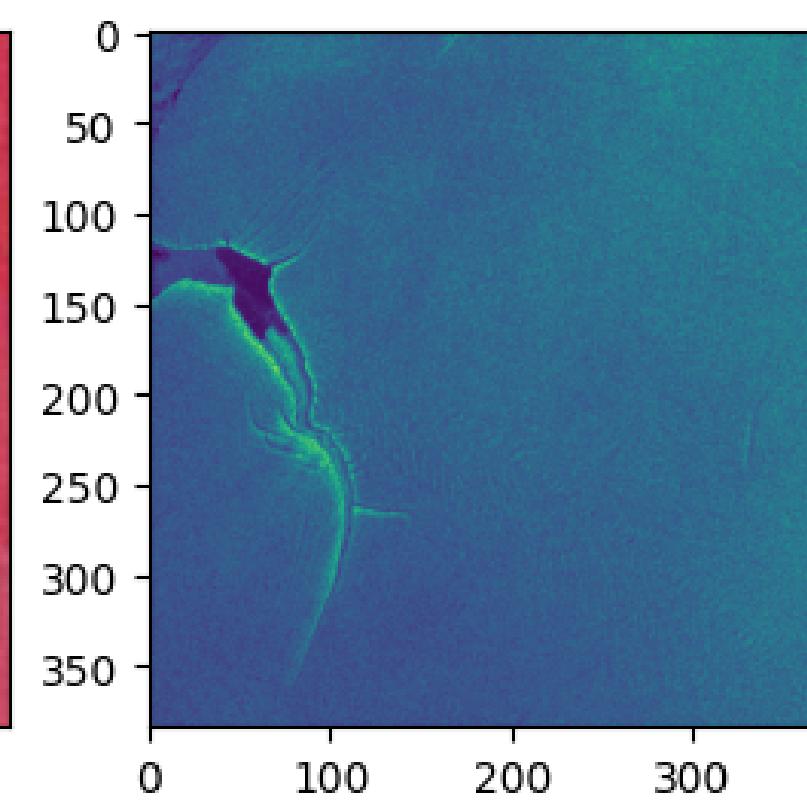
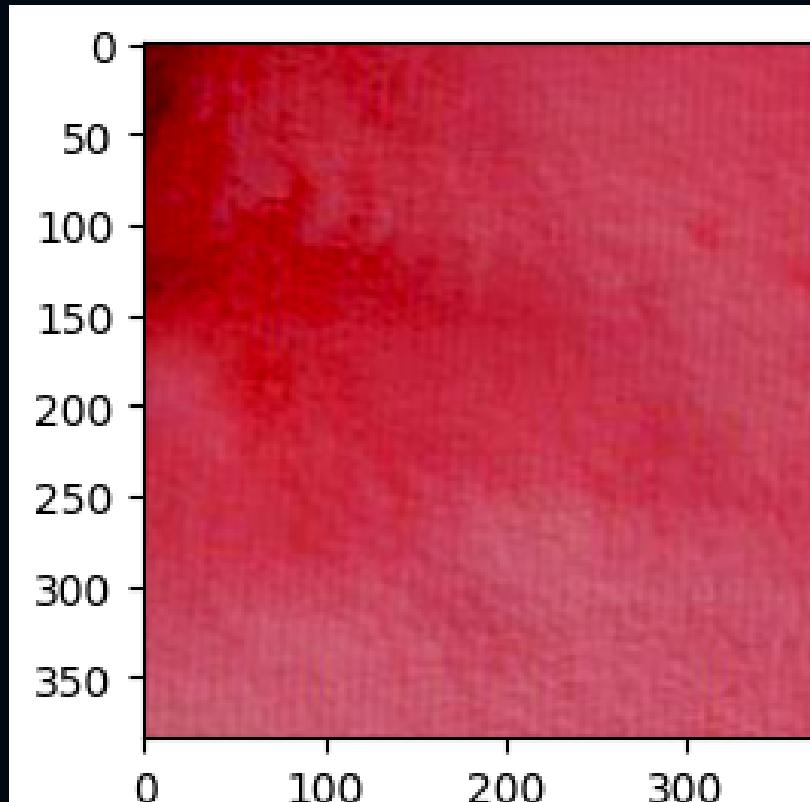
IOU: 0.627

DICE: 0.741

Pixel Accuracy: 0.764



021



Bagging

IOU: 0.708

DICE: 0.756

Pixel Accuracy: 0.921

022

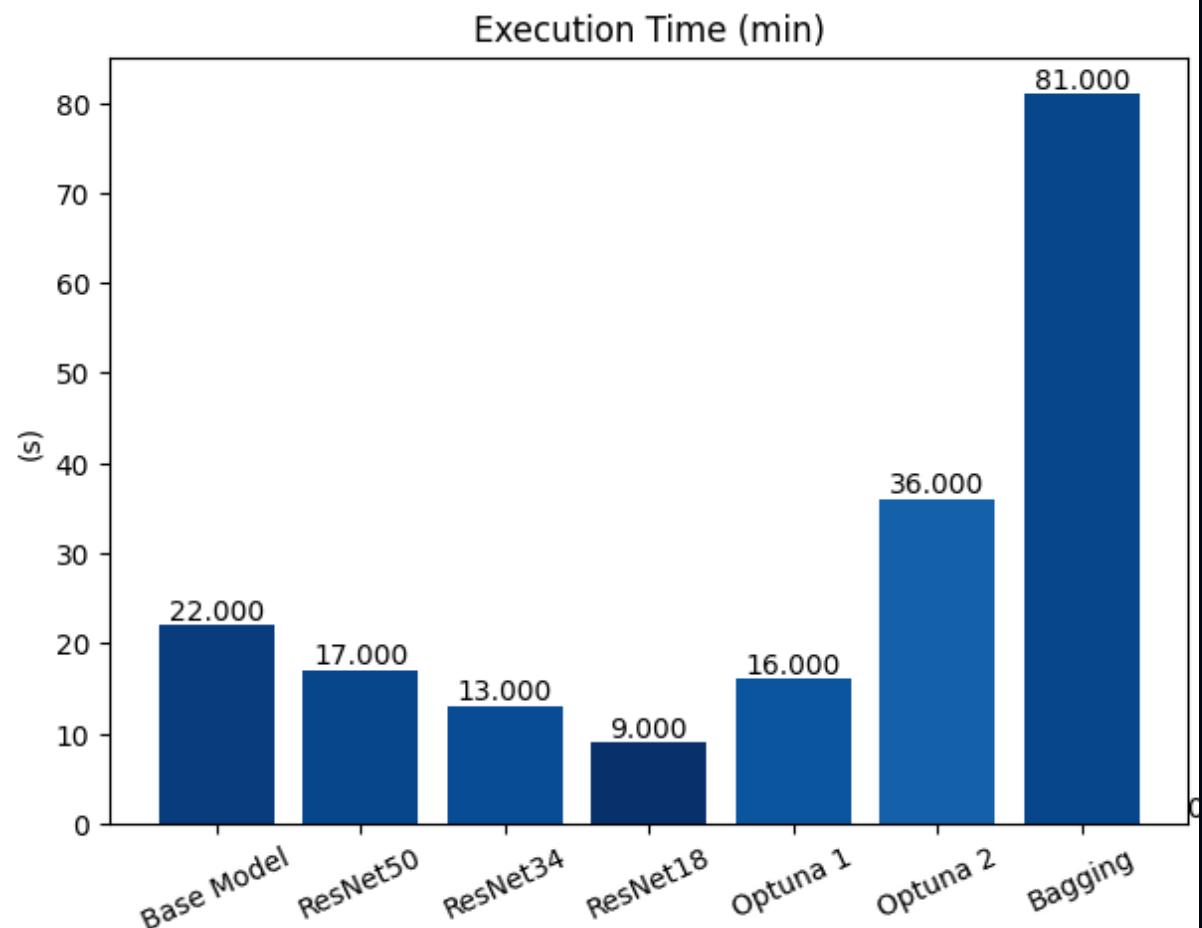
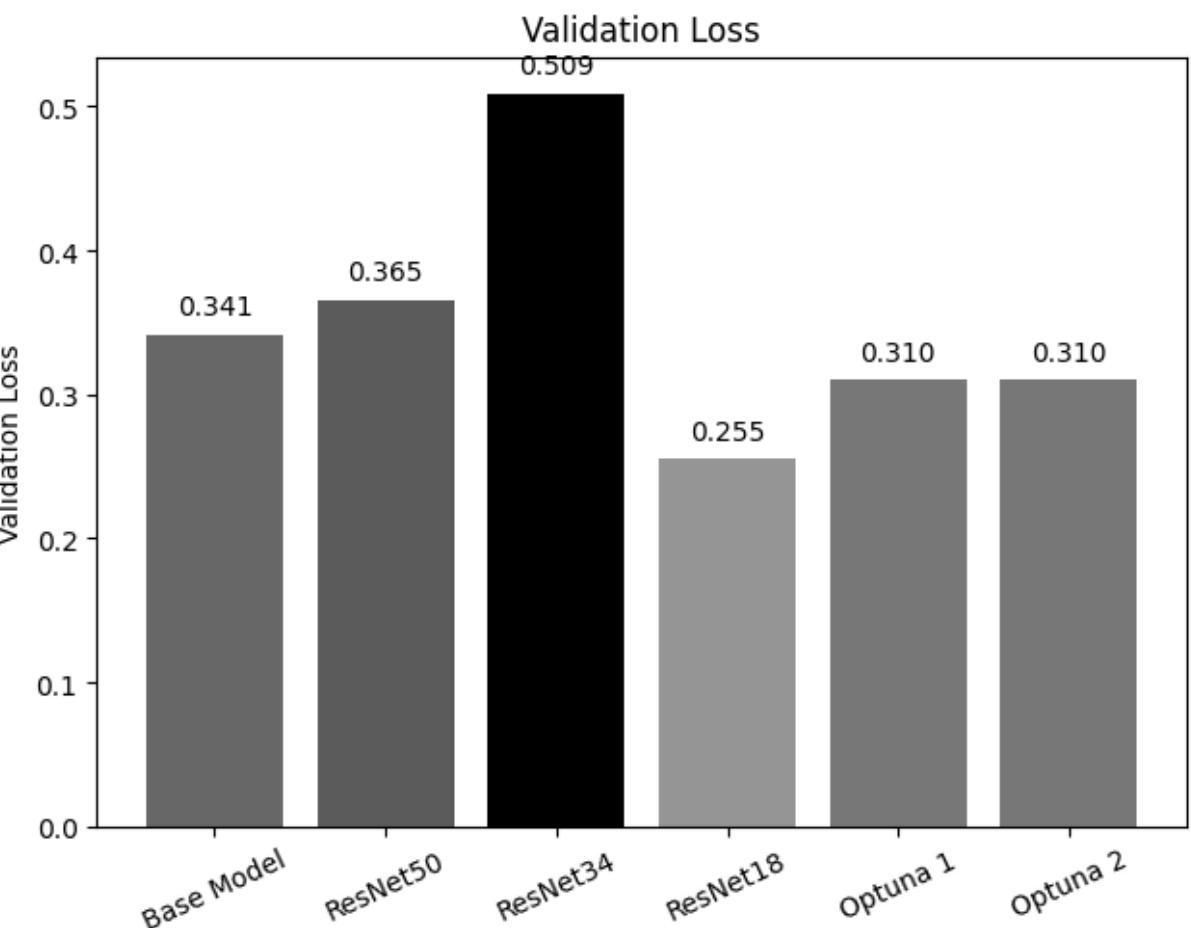
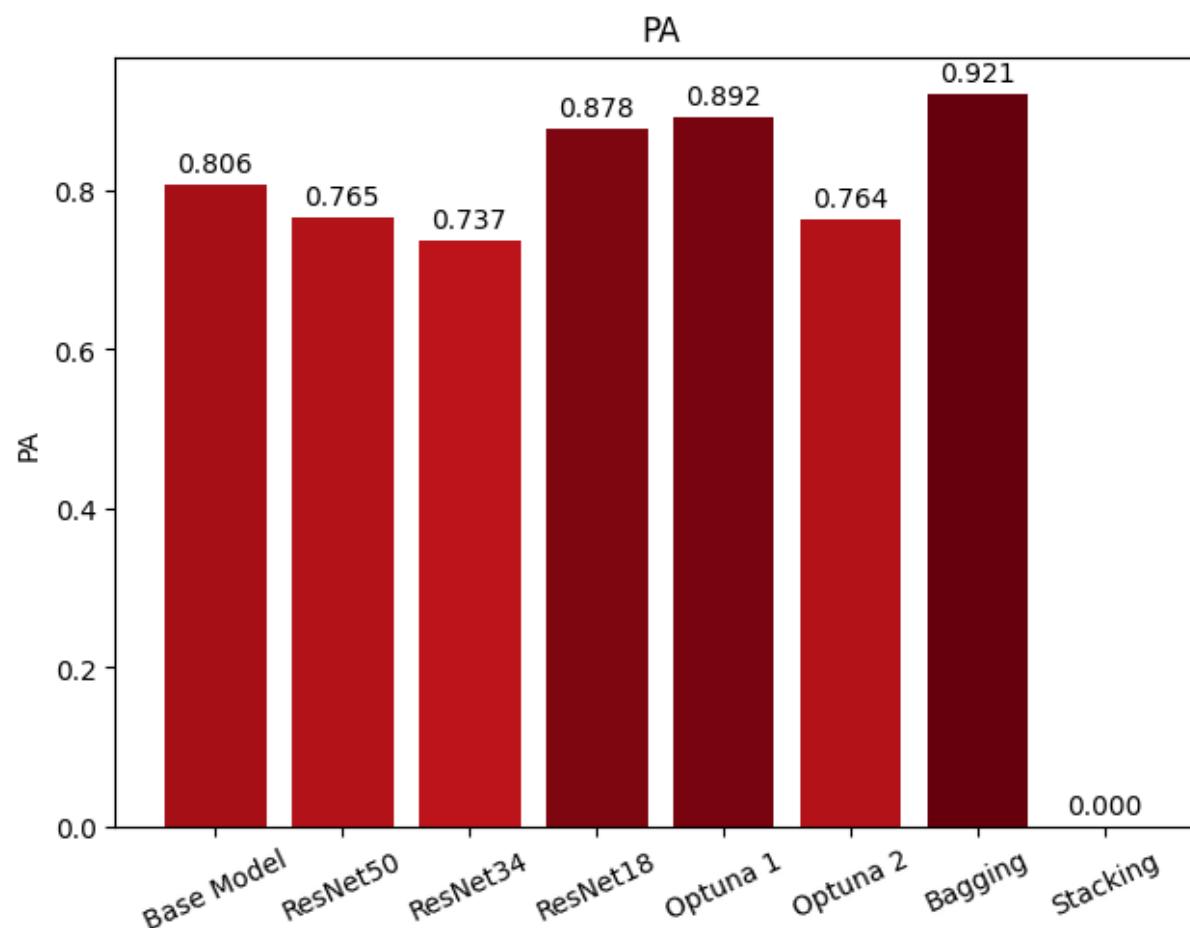
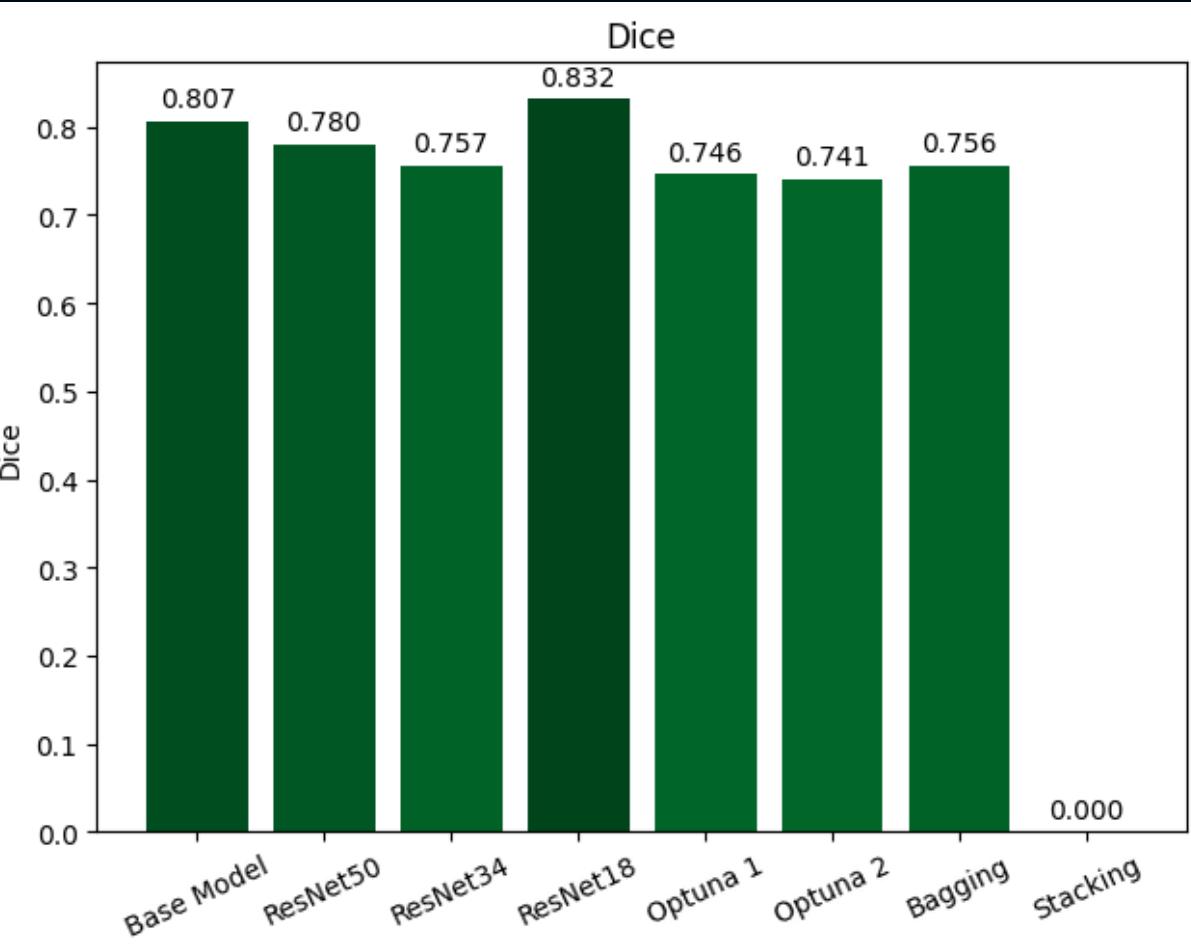
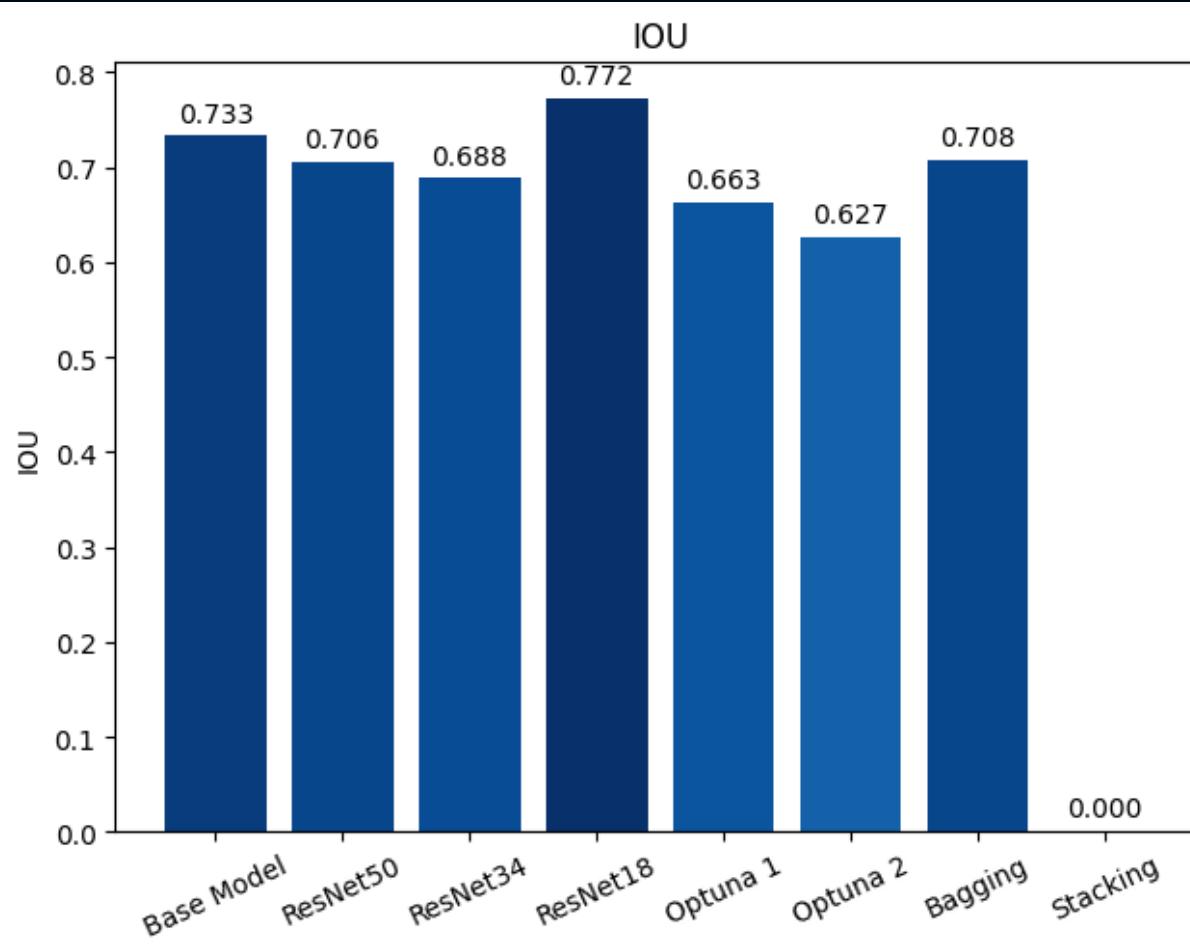


TABLE I: Models Results

Model	IoU ↑	Dice ↑	PA ↑	Val Loss ↓	Time ↓
Base	0.733	0.807	0.807	0.341	22
Base Optuna	0.662	0.746	0.892	0.310	16
Base Optuna 2	0.627	0.741	0.764	0.310	36
ResNet18	0.772	0.832	0.878	0.255	9
ResNet34	0.688	0.757	0.737	0.509	13
ResNet50	0.706	0.780	0.765	0.365	17
Bagging	0.708	0.756	0.921	-	81

Note: Times are expressed in minutes.

RESNET18



CONCLUSÕES E DISCUSSÕES

DESEMPENHO DOS MODELOS

- Os modelos **ResNet50** e **ResNet30** tendiam a sofrer *overfitting* devido ao pequeno conjunto de dados e imagens de baixa resolução.
- Modelos mais simples, como **ResNet18** e **Base UNet**, produziram melhores resultados.

MODELO DE ENSEMBLE

- Aproveita a simplicidade dos modelos base.
- Reduz a variância das previsões.
- Maior tempo de treinamento e duração das previsões.

CONCLUSÕES E DISCUSSÕES

LIMITAÇÕES DE ACESSO À GPU

- As GPUs do Google Colab tinham tempo de acesso limitado.
- Isso afetou os modelos de ensemble e as otimizações do Optuna.
- Os modelos ficaram inacabados devido à remoção de acesso durante as execuções.

TESTES DO OPTUNA

- O primeiro estudo do Optuna (10 testes) foi interrompido no 4º teste.
- O segundo estudo do Optuna (12 testes) foi interrompido no 2º teste.
- Os testes iniciais servem como uma base para modificações nos hiperparâmetros.



OBRIGADO PELA
ATENÇÃO

REFERÊNCIAS

NASA, “Global Ice Viewer” climate.nasa.gov. <https://climate.nasa.gov/interactives/global-ice-viewer/#/> (accessed Dec. 15, 2023)

T. Bralower, D. Bice, “Distribution of Water on the Earth’s Surface,” e-education.psu.edu. <https://www.e-education.psu.edu/earth103/node/701> (accessed Dec. 15, 2023)

Eilish O’Grady, Naomi Shakespeare-Rees, spiruel. (2023). “Leeds SciML Sea Ice Segmentation,” Kaggle. <https://kaggle.com/competitions/leeds-sciml-sea-ice-segmentation> (accessed Dec. 18, 2023)

Ronneberger, O., Fischer, P., Brox, T. (2015). U-Net: Convolutional Networks for Biomedical Image Segmentation. In: Navab, N., Hornegger, J., Wells, W., Frangi, A. (eds) Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015. MICCAI 2015. Lecture Notes in Computer Science(), vol 9351. Springer, Cham. https://doi.org/10.1007/978-3-319-24574-4_28

Breiman, L. Bagging predictors. *Mach Learn* 24, 123–140 (1996). <https://doi.org/10.1007/BF00058655>

Takuya Akiba, Shotaro Sano, Toshihiko Yanase, Takeru Ohta, and Masanori Koyama. 2019. Optuna: A Next-generation Hyperparameter Optimization Framework. In Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining (KDD ’19). Association for Computing Machinery, New York, NY, USA, 2623–2631. <https://doi.org/10.1145/3292500.3330701>